

天津大学

本科生毕业论文



题目：基于双通道时序信号的两阶段管道泄漏检测与定位方法

学 院	建筑工程学院
专 业	船舶与海洋工程
年 级	2022 级
姓 名	孟达
学 号	3022205024
指导教师	顾鹏

摘 要

针对管道输送系统中泄漏状态识别困难、人工特征设计依赖较强以及泄漏距离估计精度不足等问题，本文围绕双通道时序传感信号，研究了一种基于深度学习的两阶段管道泄漏检测与定位方法。首先，结合泄漏声信号形成机制与双通道传播差异，构建从原始 CSV 采样数据到训练样本的自动化处理流程，将长时序双通道信号按照固定时间窗口切分为分段样本，并分别生成分类任务与回归任务所需的数据清单。其次，面向泄漏状态识别与泄漏距离估计两个目标，设计统一的一维卷积神经网络框架。其中，分类阶段（Stage2）以单通道分段信号为输入，用于识别正常状态与两类泄漏形态；回归阶段（Stage1）以左右双通道信号对为输入，用于估计泄漏距离。最后，基于统一训练框架完成模型训练、验证与测试，并从片段级与原始文件级两个层面评价分类性能，同时采用平均绝对误差、均方根误差、容差命中率、误差方向和按距离档位拆分误差分析距离估计效果。实验结果表明，在当前随机文件级划分下，本文方法在分类任务上取得了较高识别性能，测试集片段级准确率达到 0.9968，片段级 macro-F1 达到 0.9972，按原始文件聚合后的文件级准确率与文件级 macro-F1 均达到 1.0000；在距离回归任务上，测试集平均绝对误差为 0.3703，均方根误差为 0.5934，误差不超过 1 个距离单位的片段比例为 0.9286，文件级聚合后平均绝对误差进一步降至 0.2534。上述结果说明，本文提出的两阶段方法能够有效完成管道泄漏状态识别与距离估计任务，并为后续开展更严格的泛化验证与工程部署提供实验基础。

关键词：管道泄漏检测，时序信号分析，深度学习，一维卷积神经网络，距离回归

ABSTRACT

To address the difficulty of leak state recognition, the strong dependence on hand-crafted features, and the insufficient accuracy of leak distance estimation in pipeline transport systems, this thesis studies a two-stage pipeline leak detection and localization method based on dual-channel time-series sensor signals. First, considering the generation mechanism of leakage acoustic signals and the propagation differences between two sensing channels, an automated data processing pipeline is constructed from raw CSV measurements. Long dual-channel signals are segmented with a fixed time window to generate structured samples for both classification and regression tasks. Second, a unified one-dimensional convolutional neural network framework is designed for leak state recognition and distance estimation. In the classification stage (Stage2), segmented single-channel signals are used to identify normal states and two leak patterns. In the regression stage (Stage1), paired left-right channel signals are used to estimate leak distance. Finally, a unified training framework is employed for model optimization, validation, and testing. Classification performance is evaluated at both the segment level and the original-file level, while distance estimation performance is measured by mean absolute error, root mean square error, tolerance accuracy, signed error, and distance-wise error analysis. Experimental results show that, under the current random file-level split, the proposed method achieves strong performance on the classification task, with a segment-level accuracy of 0.9968, a segment-level macro-F1 of 0.9972, and both file-level accuracy and file-level macro-F1 reaching 1.0000 on the test set. On the distance regression task, the test mean absolute error is 0.3703, the root mean square error is 0.5934, the proportion of segment-level predictions within one distance unit is 0.9286, and the file-level mean absolute error is further reduced to 0.2534 after aggregating segments from the same original file. These results indicate that the proposed two-stage method can effectively accomplish both leak state recognition and distance estimation, and provide an experimental basis for stricter generalization evaluation and engineering deployment.

KEY WORDS: Pipeline Leak Detection; Time-series Signal Analysis; Deep Learning; One-dimensional Convolutional Neural Network; Distance Regression

目 录

第一章	绪论	1
1.1	研究背景与意义	1
1.2	国内外研究现状	1
1.2.1	传统管道泄漏检测方法	1
1.2.2	基于机器学习的检测方法	2
1.2.3	基于深度学习的时序信号处理方法	2
1.2.4	注意力机制与长时序建模方法	3
1.2.5	深度学习在时序信号处理中的基础理论	4
1.3	研究问题与本文工作	4
1.4	论文结构安排	5
第二章	管道泄漏探测原理与数据集构建	6
2.1	管道泄漏探测基本原理	6
2.2	泄漏声信号形成机制	6
2.3	数据特征分析与建模需求	7
2.4	原始数据组织方式	7
2.5	长时序信号建模难点	8
2.6	标签映射与任务拆分	9
2.7	分段策略与样本生成	9
2.8	数据集统计	10
2.9	相关损失函数与优化理论	10
2.9.1	交叉熵损失与分类任务优化	10
2.9.2	Smooth L1 损失与距离回归任务优化	11
2.9.3	AdamW 优化器与余弦退火调度	11
第三章	两阶段泄漏检测模型设计	12
3.1	方法基础	12

3.2	总体框架	12
3.3	输入表示与归一化	13
3.4	一维卷积特征提取网络	13
3.5	Conformer 时序建模结构	14
3.6	分类头与回归头设计	15
3.6.1	Stage2 分类模型	15
3.6.2	Stage1 回归模型	15
3.7	训练策略	16
3.8	正则化与过拟合抑制策略	16
3.8.1	早停机制	16
3.8.2	权重衰减	16
3.8.3	梯度裁剪	17
3.8.4	批归一化的正则化效应	17
3.8.5	数据层面的泛化保障	17
第四章	实验设计与结果分析	18
4.1	实验环境与配置	18
4.2	评价指标	18
4.2.1	分类任务指标	18
4.2.2	回归任务指标	19
4.3	实验结果	20
4.3.1	Stage2 分类结果	20
4.3.2	Stage1 距离回归结果	22
4.4	结果分析	26
4.4.1	Stage2 分类结果分析	26
4.4.2	Stage1 回归结果分析	26
4.4.3	对比实验与消融实验分析	27
4.4.4	训练过程分析	29

第五章	结论与展望	30
5.1	全文总结	30
5.2	后续工作展望	31
参考文献		34
致 谢		35

第一章 绪论

1.1 研究背景与意义

管道输送系统广泛应用于能源、化工与市政基础设施等场景，是现代能源供给与物资运输的重要支撑。管道一旦发生泄漏，不仅会造成介质损失和环境污染，严重时还可能引发火灾、爆炸等次生灾害。以油气管道为例，其输送距离长、沿线地质条件复杂，传统人工巡检和定期检修难以满足连续监测与快速定位的需求。因此，利用现代传感技术与智能数据分析方法，构建面向原始传感信号的自动泄漏识别与定位方法，具有明确的工程应用价值。

传统泄漏检测方法通常依赖人工经验、阈值规则或频域特征分析。在结构简单、噪声可控的场景下，这类方法能够发挥一定作用；但面对复杂工况、长时序原始信号以及不同泄漏形态时，仍存在特征设计依赖人工、泛化能力有限和定位精度不足等问题。随着深度学习在时序建模中的应用逐渐成熟，直接从原始信号中学习判别特征，为管道泄漏检测与定位提供了新的技术路径。

基于上述问题，本文围绕双通道管道传感信号，设计一种两阶段泄漏检测框架。该框架先对分段时序信号进行状态与泄漏形态识别，再对泄漏样本进行距离估计，从而将复杂任务拆分为“状态识别”和“位置估计”两个目标明确的子问题。这种分阶段处理方式有助于降低任务耦合度，提高训练过程的稳定性与结果解释的清晰度。模型方面，本文以一维卷积网络作为基础结构，并进一步补充 Conformer 结构对比，用于分析局部卷积与自注意力结合的时序建模方式在分类与回归任务中的适用性差异。

1.2 国内外研究现状

1.2.1 传统管道泄漏检测方法

在深度学习技术普及之前，工程实践中主要依赖物理模型与信号处理方法开展管道泄漏检测。声波法通过采集泄漏点产生的声发射信号，利用信号传播时间差和衰减特性推断泄漏位置，该方法在金属管道与高压场景下应用广泛^[1]。负压波法通过监测管道压力瞬时下降产生的负压波传播时间差实现泄漏定位，对于突发性大泄漏检测效果较好，但对微小渗漏反应不灵敏。此外，流量平衡法通过比对管道进出口流量差判断泄漏状态，此方法直观易实现，但受管道输送工况波动影响较大，难以单独完成精确定位^[2]。

上述传统方法在特定条件下均能发挥作用，但存在若干共性问题：首先，对

信号质量要求较高，实际复杂噪声环境下容易发生误报或漏报；其次，检测阈值和模型参数依赖人工经验设定，难以在不同工况下保持稳定的检测性能；最后，对于非突发性微小泄漏或间歇性泄漏，传统方法往往无能为力^[3]。这些局限性促使研究者逐渐转向数据驱动的检测方法。

1.2.2 基于机器学习的检测方法

随着机器学习技术的发展，研究者开始将特征工程与分类器相结合用于管道泄漏检测^[4]。此类方法的一般流程为：首先从原始传感器信号中提取时域特征（如均值、方差、峰值因子、峭度等）和频域特征（如频谱能量分布、小波包分解系数等），然后利用支持向量机、K 近邻、决策树等分类器进行泄漏状态判别^[5]。

这类方法相比于纯物理模型方法具有以下优势：一是可以自动学习数据中的判别模式，减少对人工阈值的依赖；二是能够在训练数据覆盖的工况范围内保持较好的检测效果。然而，传统机器学习方法仍然面临特征工程环节的设计瓶颈——人工提取的特征往往无法完整保留原始信号中的细粒度信息，且特征对不同泄漏形态、不同距离的区分度存在明显差异^[6]。此外，特征提取与分类器优化通常是分离进行的，无法实现端到端的联合优化。

1.2.3 基于深度学习的时序信号处理方法

近年来，深度学习在时序信号处理领域取得了显著进展。相比于传统方法，神经网络可以直接从原始信号中学习层次化的特征表示，避免了人工特征设计的主观性和不完整性^[7]。这种端到端的学习范式在大幅降低人工参与的同时，也使得模型能够发现人类专家可能忽略的细粒度信号模式。

在信号处理领域，一维卷积神经网络（1D-CNN）是最为常用的深度模型之一^[8]。1D-CNN 通过在时序维度滑动一维卷积核提取局部模式，并利用多层堆叠逐步扩大感受野，从而同时捕获局部波形特征与全局上下文信息。相比循环神经网络（RNN）及其变体 LSTM，1D-CNN 具有训练并行度高、参数量可控、梯度传播稳定等优势，更适合处理长度较长的时序信号^[6]。

在管道泄漏检测方面，Zhang 等人^[9]较早将 CNN 应用于管道声发射信号，验证了卷积网络在泄漏分类任务中的有效性。在此基础上，后续工作通过引入多尺度卷积^[2]、注意力机制^[2]等方式进一步提升检测精度。然而，现有工作大多将泄漏状态识别与位置估计作为单一任务处理，对分类目标与回归目标之间差异性的利用仍不充分。本文针对这一问题，采用“先分类、后定位”的两阶段处理框架，以降低单一模型的学习负担，并提升系统的可解释性与模块化程度。

1.2.4 注意力机制与长时序建模方法

除卷积神经网络外，注意力机制近年来也被广泛用于时序信号建模。注意力机制的基本思想是：模型在处理一个序列时，不再对所有时间位置赋予完全相同的重要性，而是根据当前任务目标自动学习不同位置之间的相关程度。对于长时序传感信号而言，某些局部时间片段可能包含明显泄漏特征，例如瞬态冲击、能量突变或周期性振荡；另一些片段则可能主要由背景噪声或稳定运行信号构成。若模型能够自动关注更具判别性的时间区域，就可能提升对复杂波形的识别能力。

自注意力机制是注意力机制在序列内部的一种典型形式。其核心过程可以概括为：首先将输入序列映射为查询（Query）、键（Key）和值（Value）三个向量空间；然后计算不同时间位置之间的相似度，并根据相似度对值向量进行加权求和。对于输入特征矩阵 $\mathbf{X}$ ，自注意力可写为：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (1-1)$$

其中， $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$ 分别表示查询、键和值矩阵， d_k 为键向量维度。缩放因子 $\sqrt{d_k}$ 用于避免点积数值过大导致 Softmax 输出过于尖锐，从而保持梯度传播稳定。与卷积操作只在局部窗口内建模不同，自注意力理论上可以直接建立序列中任意两个时间位置之间的联系，因此更适合表达长程依赖关系。

多头注意力机制进一步将特征划分为多个子空间，并在每个子空间中独立计算注意力。不同注意力头可以学习不同类型的相关性：有的注意力头可能关注短时冲击，有的可能关注较长时间范围内的能量分布，还有的可能关注某些重复出现的波形片段。最终，各个注意力头的输出被拼接并线性变换，形成综合特征表示。对于泄漏信号而言，这种机制有助于模型同时关注多种时间尺度上的信号模式。

不过，注意力机制也存在明显局限。首先，标准自注意力的计算复杂度与序列长度的平方成正比。当输入长度达到数万甚至十几万个采样点时，直接使用标准 Transformer 结构会带来极高的显存和计算开销。其次，自注意力本身不具备卷积那样的局部平移不变性，若缺少合适的位置编码和局部建模模块，模型可能难以稳定捕获短时波形边缘、局部振荡和瞬态冲击等细粒度模式。因此，在长时序物理信号建模中，单独依赖注意力机制并不一定优于卷积结构，更常见的做法是将卷积的局部特征提取能力与注意力的全局建模能力结合起来。

Conformer 正是在这一背景下形成的卷积-注意力混合结构。它一方面通过卷积模块保留局部时序建模能力，另一方面通过自注意力模块补充长程依赖建模能力。对于本文的管道泄漏信号，局部卷积能够捕获泄漏引起的局部波形变化，

自注意力则有助于比较同一窗口内不同时间位置之间的响应关系。因此，本文将 Conformer 作为一维 CNN 的结构扩展，用于检验更强的上下文建模是否能够在分类识别和距离回归两个任务中带来一致收益。

1.2.5 深度学习在时序信号处理中的基础理论

本节简要回顾与本文方法密切相关的深度学习基础理论，为后续章节的模型设计提供理论支撑。

卷积神经网络的核心操作是卷积运算。对于一维输入信号 $\mathbf{x} \in \mathbb{R}^L$ 和卷积核 $\mathbf{w} \in \mathbb{R}^K$ ，卷积输出的第 t 个元素可表示为：

$$y_t = \sum_{k=0}^{K-1} w_k \cdot x_{t+k} \quad (1-2)$$

通过堆叠多个卷积层，网络能够逐层学习从低级到高级的特征表示。较低层主要响应信号中的局部波形模式（如突变、振荡），较高层则组合这些模式形成对特定泄漏形态的全局判别依据^[7]。

批归一化（Batch Normalization）是深度网络训练中的关键正则化技术^[10]。对于某一层的小批量输入 $\{z_1, z_2, \dots, z_m\}$ ，批归一化先计算批内均值 μ_B 与方差 σ_B^2 ，再进行如下变换：

$$\hat{z}_i = \frac{z_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad \tilde{z}_i = \gamma \hat{z}_i + \beta \quad (1-3)$$

该机制能够缓解训练过程中各层输入分布变化带来的不稳定性，使得梯度传播更加顺畅，从而允许使用更高的学习率和更少的正则化约束^[10]。

在激活函数方面，本文采用 GELU（Gaussian Error Linear Unit）^[11]。GELU 的数学形式为 $\text{GELU}(x) = x \cdot \Phi(x)$ ，其中 $\Phi(x)$ 为标准正态分布的累积分布函数。与 ReLU 的硬门控机制直接将负值置零不同，GELU 根据输入值以概率方式决定激活程度，在负值区域保留了部分信息。这种平滑的非线性变换有助于梯度在负值区域仍然有效传播，避免了 ReLU 中“神经元死亡”现象。实验表明其在多种视觉和信号处理任务中优于 ReLU^[11]。

1.3 研究问题与本文工作

结合现有数据条件与工程实现需求，本文关注的核心问题可以概括为：如何利用双通道长时序传感信号，在尽量减少人工特征设计的前提下，实现管道泄漏状态识别与泄漏距离估计。

围绕上述问题，本文完成了以下工作：

1. 设计了原始 CSV 信号到训练样本的自动化构建流程。针对原始双通道数据，按照固定时间窗口完成切分，并分别构建分类任务与回归任务所需的数据清单。
2. 构建了两阶段学习任务。其中，分类阶段（Stage2）用于识别信号所属类别，回归阶段（Stage1）用于对泄漏距离进行估计。
3. 设计并实现了适用于长时序一维信号的基础卷积模型，同时接入 Conformer 时序建模结构作为扩展对比。卷积模型通过多层一维卷积逐步降采样，Conformer 则在降采样后进一步结合局部卷积与自注意力机制建模长程上下文。
4. 搭建了统一训练框架，并在分类任务中补充片段级与原始文件级评测指标，包括准确率、macro-F1 和混淆矩阵；在回归任务中除平均绝对误差与均方根误差外，进一步补充误差方向、容差命中率、按距离档位误差和文件级聚合误差分析。同时，本文通过传统机器学习基线、通道消融和 CNN-Conformer 结构对比分析不同建模方式的适用边界。

1.4 论文结构安排

本文按照研究问题、数据与方法、实验验证和总结展望的逻辑主线组织。全文共分为五章，各章内容安排如下：

1. 第一章为绪论，介绍研究背景、研究意义、研究问题与本文主要工作。
2. 第二章介绍管道泄漏探测的基本原理、泄漏声信号形成机制、信号数据特征以及数据集构建过程。
3. 第三章介绍本文所用深度学习方法基础、两阶段泄漏检测模型的整体结构、网络设计与训练策略。
4. 第四章介绍实验设计、评价指标与结果分析，重点讨论分类性能、距离估计误差、统计基线对比及影响因素。
5. 第五章总结全文工作，并对后续改进方向进行展望。

第二章 管道泄漏探测原理与数据集构建

2.1 管道泄漏探测基本原理

管道泄漏检测的核心目标是从传感器采集到的压力、振动或声学响应中识别异常状态，并进一步推断泄漏位置。管道处于正常运行状态时，内部流体流动与外部结构响应通常保持相对稳定；当管壁出现孔洞、裂纹或连接处密封失效时，流体会在压差作用下从破损位置喷出，局部流场发生突变，并激发与泄漏有关的瞬态波动和持续扰动。这些扰动沿管壁和流体介质传播，被布置在不同位置的传感器接收后形成可观测的时序信号。

从信号分析角度看，泄漏探测可以理解为从原始时序信号中提取能够区分正常状态、泄漏形态以及泄漏位置的特征。传统方法通常依赖时域统计量、频域能量分布或人工阈值规则；深度学习方法则直接从原始波形中学习特征表示。本文采用后一种思路，以固定长度的分段信号为输入，首先通过一维卷积网络自动提取局部波形模式和跨通道差异，并进一步利用 Conformer 结构检验自注意力上下文建模对不同任务的影响，从而完成泄漏识别与距离估计。

2.2 泄漏声信号形成机制

泄漏声信号的形成主要来源于泄漏点附近流体状态的突变。当管道内部介质经泄漏孔口向外喷射时，局部区域会产生湍流、压力脉动和结构振动。这些扰动一方面沿流体传播，另一方面也会耦合到管壁结构中形成振动响应，最终被布置在管道不同位置的传感器采集为时序波形信号。泄漏信号的频率成分和幅值大小受泄漏孔尺寸、管道压力、介质类型和环境背景噪声等多种因素共同影响，不同泄漏形态在时域波形和频域能量分布上可能表现出不同的特征模式。

对于布置在管道不同位置的左右两个传感通道而言，同一泄漏事件到达两个传感位置的传播路径、衰减程度和相位关系并不完全相同。泄漏点距离某一传感器越近，该通道的信号响应通常越早、幅值衰减越小；反之，波形能量衰减更明显，响应也可能更晚。因此，双通道信号之间的幅值差异、相位偏移和局部波形差异共同构成了泄漏距离估计的物理依据。

具体而言，若泄漏点靠近某一侧传感器，该侧通道可能表现出更明显的幅值变化、更早的响应或不同的局部频率成分；若泄漏点位于两侧传感器之间的不同位置，左右通道之间的相关性、能量差异和波形形态也会随之变化。本文没有手工构造到达时间差或频域峰值等特征，而是保留左右通道原始分段信号，由卷积

网络在训练过程中学习这些隐含差异。

2.3 数据特征分析与建模需求

本文实验数据具有以下特点。第一，单段信号长度较长。采样率为 25600 Hz、窗口长度为 5 s 时，每个通道包含 128000 个采样点，直接使用全连接网络建模会带来较高参数量和过拟合风险，因此需要采用具有参数共享机制的一维卷积网络进行降维处理。第二，信号具有典型时序连续性，相邻采样点之间并非独立取值，而是呈现连续波形起伏规律，这使得局部卷积适合提取短时波形模式。第三，回归任务使用左右双通道输入，通道间差异本身具有定位意义。同一泄漏事件在左右两个传感位置上的响应会随泄漏点相对位置变化而变化，因此模型需要同时利用单通道局部特征和双通道联合特征。第四，距离标签虽然以回归形式使用，但实际取值为若干离散档位。因此，实验分析不能只看总体平均误差，还应关注不同距离档位上的误差差异。

基于上述特征，本文在数据处理时采用固定窗口切分和逐段标准化，在模型设计时以多层一维卷积逐步降采样作为基础方案，并补充 Conformer 结构用于观察更强时序上下文建模是否能够改善性能。在结果分析时，本文同时报告总体指标、按原始文件聚合后的指标以及按距离档位拆分的误差表现。

2.4 原始数据组织方式

本项目原始数据以 CSV 文件形式存储，并按照是否泄漏划分为泄漏样本与正常样本两类。每个文件对应一组实验采样记录，文件名采用 ABC 编号形式，例如 ABC91.csv。数据样本包含左右两个传感通道，分别对应后续建模中使用的左通道信号与右通道信号。数据处理脚本统一读取原始文件，跳过首行后将信号转为数值矩阵。

这种数据组织方式具有两个优点。其一，原始信号与实验编号一一对应，便于依据编号映射标签；其二，双通道结构保留了泄漏传播在不同传感位置上的响应差异，为距离估计提供了数据基础。此外，CSV 格式便于直接查看和调试，降低了数据处理流程的维护成本。

从实验复现角度看，文件级组织还可以避免数据划分中的潜在信息泄漏。如果直接以切分后的片段为单位随机划分训练集和测试集，同一原始文件中相邻片段可能同时出现在不同数据子集中，导致训练集与测试集之间存在较强相似性，进而高估模型泛化能力。因此，本文在数据划分时以原始文件或文件组为基本单位，使同一原始实验记录生成的全部片段只属于一个数据子集。该策略能够更接近实际应用场景：模型在测试阶段面对的是未参与训练的完整实验记录，而不是

同一记录中被切分出的相邻片段。

2.5 长时序信号建模难点

本文处理的泄漏信号属于典型长时序数据。与图像、结构化表格或短序列文本相比，长时序传感信号具有更强的连续性、更高的冗余度和更明显的噪声干扰。单个 5 s 窗口包含 128000 个采样点，其中真正与泄漏状态或泄漏位置强相关的片段可能只占一部分；大量采样点反映的是背景振动、稳定运行噪声或与任务无关的局部波动。这意味着模型不仅要提取有效特征，还要在大量冗余信息中抑制无关扰动。

首先，长序列带来较高的计算成本。若直接将全部采样点输入全连接网络，参数量会随输入长度线性增加，并且会破坏时序局部结构；若直接使用标准自注意力结构，注意力矩阵的尺寸会随序列长度平方增长，难以在普通硬件上完成训练。因此，本文采用“先局部降采样、再高层建模”的思路：一维 CNN 通过带步长卷积逐层压缩时间长度，Conformer 也先利用卷积前端降低序列长度，然后再进行注意力计算。这种设计兼顾了计算可行性与上下文建模能力。

其次，泄漏信号中的有效模式具有多尺度特征。一些泄漏形态可能表现为局部尖峰或短时冲击，需要较小时间范围内的卷积核捕获；另一些形态可能表现为持续的能量变化、周期性振荡或长时间范围内的统计差异，需要模型具有更大的感受野。单一尺度的特征提取方式容易遗漏某些模式，因此本文基础 CNN 采用多层不同大小卷积核，Conformer 则通过卷积模块和自注意力模块进一步补充局部与全局信息。

再次，分类任务与回归任务对特征的要求并不一致。分类任务只需要判断信号属于哪一种状态或泄漏形态，模型可以依赖较强的类别判别特征；即使某些片段预测错误，文件级聚合也能通过多数片段的稳定判断降低误差。而距离回归任务要求模型输出连续数值，且相邻距离档位之间可能只存在细微通道差异，这使得回归任务更容易受到噪声、样本不均衡和局部异常片段的影响。也正因为如此，本文在实验部分分别报告片段级和文件级结果，并额外分析不同距离档位上的误差分布，而不是仅给出一个总体平均指标。

最后，双通道输入虽然为定位提供了物理依据，但也增加了建模复杂度。模型需要同时学习每个通道内部的局部波形模式，以及两个通道之间的相对关系。对于回归任务而言，左右通道的幅值差异、相位差异、局部相关性和传播衰减特征都可能与距离有关；但这些信息并不会以显式变量形式出现，而是隐藏在原始波形之中。因此，本文将双通道输入作为 Stage1 的核心设计，并通过单通道消融实验验证通道间差异对定位任务的必要性。

2.6 标签映射与任务拆分

数据准备脚本 `src/leak_detection/cli/prepare_dataset.py` 中定义了编号到标签的映射规则。对于发生泄漏的实验样本，每个编号区间同时对应两个标签信息：一是泄漏距离 `distance`，二是泄漏形态类别 `shape`；对于正常样本，则只赋予正常类别标签，不参与距离回归任务。

基于这一映射关系，本文将原始问题拆分为两个子任务：

1. Stage2 为分类任务。输入为单通道分段信号，当前输出为五类标签，用于区分正常状态与多类泄漏形态。
2. Stage1 为回归任务。输入为同一时间窗口下的左右双通道信号对，输出为泄漏距离，用于估计泄漏位置。

这种两阶段设计的考虑在于：状态识别与距离估计虽然共享同一信号来源，但学习目标并不相同。状态识别关注整体波形形态差异，属于离散判别任务；距离估计关注双通道传播差异与泄漏距离之间的数值映射，属于回归任务。若直接使用单一模型同时完成两类目标，模型需要在同一特征空间中兼顾分类边界与回归精度，训练目标可能相互干扰。先完成状态判别，再针对泄漏样本进行距离估计，可以降低任务耦合度，使模型结构和实验分析更加清晰，也便于分别优化两个阶段的配置。

2.7 分段策略与样本生成

在数据处理过程中，原始长时序信号按照固定窗口进行切分。项目中默认采样率为 25600 Hz，分段时长为 5 s，因此单段样本长度为：

$$L = 25600 \times 5 = 128000 \quad (2-1)$$

对于每一个原始实验文件，脚本分别读取左通道与右通道数据，并按不重叠窗口进行切段。每个时间窗口都被保存为独立 CSV 文件，从而得到可直接供模型读取的分段样本。对于分类任务，左右通道被视为两条独立单通道样本；对于回归任务，左右通道在相同时间窗口下配对，形成双通道输入。

固定窗口非重叠切分方式具有实现简单、样本规模可扩展和便于批量训练等优点。对于长度为 5 秒的窗口，每个原始文件可生成多个分段样本，从而扩充训练数据规模；固定长度输入也便于卷积网络统一建模，无需引入可变长序列处理机制。不过，该策略没有显式建模不同窗口之间的时序关联，跨窗口上下文信息在当前方法中尚未被利用。此外，窗口长度本身是关键超参数：窗口过短可能导致单个样本信息不足，窗口过长则会减少样本数量并增加单样本计算开销。后续

可进一步考虑重叠切窗、多分辨率切分或序列级建模方法。

2.8 数据集统计

本文所使用的数据规模根据生成后的训练清单统计，结果如表2-1所示。

表 2-1 数据集统计结果

任务	样本数量	监督目标
Stage2 分类	11704	五分类标签
Stage1 回归	3737	泄漏距离

其中，Stage2 任务按训练集、验证集和测试集划分后分别包含 7940、2464 和 1300 条单通道样本；Stage1 任务分别包含 2532、758 和 447 对双通道样本。分类任务由五个类别构成，包含正常状态与多种泄漏形态。回归任务只使用泄漏样本，因为正常样本不存在泄漏距离这一物理量，不适合作为距离回归监督信号。

从样本构成上看，分类任务的样本数量明显多于回归任务。这是因为分类阶段将左右通道分别作为独立单通道样本使用，而回归阶段需要将同一时间窗口下的左右通道配对为一个双通道样本；同时，正常样本只参与分类任务，不参与距离回归任务。这样的任务拆分使分类模型能够充分利用正常与泄漏样本之间的差异，而回归模型则集中学习泄漏样本内部的双通道传播差异，有助于降低不同监督目标之间的干扰。

2.9 相关损失函数与优化理论

本节从优化目标的角度介绍本文两阶段任务中使用的损失函数与优化方法，为第三章模型训练策略提供理论依据。

2.9.1 交叉熵损失与分类任务优化

对于 Stage2 五分类任务，本文采用交叉熵损失函数。交叉熵来源于信息论中的 Kullback-Leibler 散度，用于衡量模型预测概率分布与真实标签分布之间的差异。设真实标签 y 对应的 one-hot 编码为 $\mathbf{y} \in \{0, 1\}^C$ ，模型输出的类别概率为 $\hat{\mathbf{y}} \in [0, 1]^C$ ，则交叉熵损失定义为：

$$\mathcal{L}_{ce} = - \sum_{c=1}^C y_c \log \hat{y}_c \quad (2-2)$$

交叉熵损失具有两个重要性质。第一，当预测概率 $\hat{y}_c$ 完全匹配真实标签时损失为零，偏离越大则损失越大，梯度也会随之增大，从而驱动模型更快速地校正错误预测。第二，Softmax 函数与交叉熵的组合在反向传播时具有简洁的梯度形式 $\nabla_{\mathbf{z}} \mathcal{L}_{ce} = \hat{\mathbf{y}} - \mathbf{y}$ ，其中 $\mathbf{z}$ 为 Softmax 前的 logits 向量，避免了梯度饱和问题。上述特性使得交叉熵成为分类任务中最常用的损失函数之一。

2.9.2 Smooth L1 损失与距离回归任务优化

对于 Stage1 距离回归任务，本文采用 Smooth L1 损失^[7]，其分段定义为：

$$\mathcal{L}_{sl1}(d, \hat{d}) = \begin{cases} \frac{1}{2}(d - \hat{d})^2, & |d - \hat{d}| < 1 \\ |d - \hat{d}| - \frac{1}{2}, & |d - \hat{d}| \geq 1 \end{cases} \quad (2-3)$$

Smooth L1 的设计动机在于结合 L1 损失与 L2 损失的优点。当误差较小时 ($|d - \hat{d}| < 1$)，Smooth L1 退化为 L2 损失，提供光滑的梯度过渡，有利于精细调整；当误差较大时，Smooth L1 退化为 L1 损失，梯度绝对值恒为 1，避免了 L2 损失在大误差下梯度爆炸的风险。这一特性对于泄漏距离估计尤为重要——由于距离标签取值为多个离散档位，模型难免在部分样本上出现较大偏离，Smooth L1 可以有效控制此类离群样本对整体训练的影响，保障训练的稳定性。

2.9.3 AdamW 优化器与余弦退火调度

本文采用 AdamW 优化器^[12] 进行参数更新。AdamW 是在 Adam 基础上做出的改进，其核心区别在于将权重衰减 (L2 正则化) 与自适应学习率更新解耦。在标准 Adam 中，权重衰减项与梯度自适应项耦合，导致正则化效果受到学习率缩放的影响；AdamW 将权重衰减直接作用于参数更新步中，使得正则化强度独立于当前自适应学习率，从而获得更好的泛化性能。

在学习率调度方面，本文采用余弦退火策略。该策略使学习率沿着余弦曲线从初始值逐步衰减至接近零，数学形式为：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \left(\frac{t}{T} \pi \right) \right) \quad (2-4)$$

其中 $\eta_{\max}$ 为初始学习率， $\eta_{\min}$ 为最终学习率， t 为当前训练轮数， T 为总训练轮数。余弦退火在训练初期保持较高学习率以快速收敛，后期以较小学习率进行精细调节，有助于模型收敛到更优的局部极小点。

第三章 两阶段泄漏检测模型设计

3.1 方法基础

本文模型属于监督学习框架。给定输入信号 x 与对应标签 y ，模型通过参数化函数 $f_{\theta}(x)$ 建立从信号到类别或距离的映射关系，并通过最小化损失函数更新参数 θ 。对于分类任务，标签为离散类别，训练目标是提高类别判别准确性；对于距离回归任务，标签为连续数值，训练目标是减小预测距离与真实距离之间的偏差。

一维卷积神经网络适用于处理时序信号。卷积核沿时间轴滑动，在局部窗口内共享参数，从而能够提取局部波形变化、短时冲击响应和局部振荡模式。与直接连接所有采样点的全连接网络相比，一维卷积具有参数共享和局部感受野的特点，能够在较少参数量下处理较长序列。随着网络层数增加，后续特征能够覆盖更大的时间范围，从而形成由局部到全局的多层次表示。

在本文任务中，批归一化用于缓解不同批量特征分布波动带来的训练不稳定问题，GELU 激活函数用于增强非线性表达能力，自适应平均池化用于将不同时间位置上的高维特征压缩为固定长度的全局表示。优化器采用 AdamW，其在 Adam 自适应学习率更新基础上引入解耦权重衰减，有助于提升训练稳定性并降低过拟合风险。

3.2 总体框架

本文采用的模型框架可概括为“数据切分、分类识别、距离估计”三个环节。首先，将原始双通道采样信号按照固定时间窗口切分为固定长度片段，并进行逐段标准化；其次，利用单通道分类模型（Stage2）对每个分段信号进行状态识别，判断其属于正常状态还是某一类泄漏形态；最后，对判定为泄漏的信号片段，利用双通道回归模型（Stage1）估计泄漏距离。分类与回归两个阶段采用独立模型参数，训练和推理时分别加载对应配置文件。网络结构上，本文以一维 CNN 作为基础模型，并在相同数据划分下接入 Conformer 作为结构扩展，用于比较局部卷积建模与卷积-注意力混合建模在两类任务上的表现差异。

从代码实现角度看，任务入口统一由 `src/leak_detection/cli/train.py` 调用训练器，训练器根据配置文件自动选择任务类型、数据集类和网络结构。这种统一入口使分类任务与回归任务共享训练流程，并仅在数据组织、损失函数和评价指标上进行区分。当前配置文件同时包含一维 CNN 与 Conformer 两类模型，训练器

通过 `model.type` 字段选择对应网络，因此结构对比实验能够在相同数据、优化流程和评价指标下完成。

3.3 输入表示与归一化

模型输入由 `src/leak_detection/data/segmented.py` 完成读取。对于分类任务，每个样本为形状 1×128000 的单通道张量；对于回归任务，每个样本由左右通道堆叠形成形状 2×128000 的双通道张量。

考虑到不同实验样本的信号幅值范围可能存在差异，代码中对每个样本执行逐段标准化处理。设原始信号为 x ，均值为 μ ，标准差为 σ ，则归一化后的信号为：

$$\hat{x} = \frac{x - \mu}{\sigma + 10^{-6}} \quad (3-1)$$

当标准差接近零时，仅进行去均值操作，以避免除零问题。该策略有助于降低量纲差异对训练过程的影响，使网络更关注波形形态与通道间相对变化。

3.4 一维卷积特征提取网络

本文采用的一维卷积主干网络定义于 `src/leak_detection/models/signal_models.py`。网络由若干级卷积模块堆叠而成，每一级模块均包含以下操作：

1. 一层带步长的一维卷积，用于完成特征提取与时域降采样；
2. 批归一化层，用于稳定训练过程；
3. GELU 激活函数，用于增强非线性表达能力；
4. 第二层一维卷积与批归一化、GELU 组合，用于进一步提取局部模式。

模型配置中卷积通道数依次设置为 32、64、128 和 256，对应卷积核大小分别为 15、9、7 和 5，步长均为 4。通过四层降采样，每一层将时序长度缩减为原来的四分之一，原始 128000 点信号经过四层卷积后长度约为 $128000/4^4 = 500$ 。这种逐步压缩的设计使早期卷积层侧重捕获局部波形细节（如突变、振荡），后期卷积层则在更粗的时间尺度上组合局部信息，形成全局判别依据。经过多层卷积之后，模型采用自适应平均池化将所有位置的特征聚合为固定长度的全局特征向量，再通过全连接任务头映射到分类或回归输出空间。

这一结构实现简单、参数量可控，适合处理长度较长的一维信号。相比需要更大算力与更复杂位置编码机制的序列模型，一维卷积网络在当前数据规模和实验条件下更易训练，也更便于工程复现。因此，本文将其作为基础模型和主要分析对象。

3.5 Conformer 时序建模结构

为进一步考察长时序上下文建模对泄漏识别与距离估计的影响,本文在一维 CNN 基础上补充 Conformer 结构对比。Conformer 原本常用于语音等长序列建模任务,其核心思想是在同一网络块中结合自注意力机制和卷积模块:自注意力用于捕获较长时间范围内的依赖关系,卷积模块用于保留局部时序模式。对于泄漏信号而言,局部波形突变、振荡形态和跨窗口上下文都可能包含判别信息,因此 Conformer 可以作为一种更强的时序建模候选结构。

本文实现的 Conformer 模型首先通过若干带步长的一维卷积层对原始长序列进行下采样,将 128000 点输入压缩到较短的时间特征序列;随后将特征映射到固定维度的隐空间,并堆叠多个 Conformer 编码层。每个编码层包含前馈网络、多头自注意力、卷积模块和归一化操作。最后,模型通过全局池化获得固定长度表示,并接入与一维 CNN 相同形式的分类头或回归头。

从模块组成看,Conformer 编码层通常由前馈网络模块、多头自注意力模块、卷积模块和第二个前馈网络模块构成,并配合残差连接与归一化操作。前馈网络负责对每个时间位置上的特征进行非线性变换,相当于在特征维度上增强表达能力;多头自注意力负责建立不同时间位置之间的全局联系,使模型能够比较同一窗口内远距离片段之间的相似性与差异性;卷积模块则负责补充局部建模能力,避免模型只依赖全局注意力而忽略短时波形结构。残差连接使每个模块学习对输入特征的增量修正,有助于稳定深层网络训练。

在泄漏检测场景中,这种结构具有明确的建模含义。泄漏信号并不总是表现为单个时间点上的异常,而可能体现为一段时间内的能量持续变化、多个局部振动片段之间的相关模式,或不同频率成分在时间上的组合变化。卷积模块更擅长捕获“某个局部区域是否出现特定形态”,而自注意力模块更擅长捕获“不同区域之间是否存在共同模式或互相印证的关系”。因此,Conformer 可以被理解为在 CNN 局部特征提取基础上增加了一层全局关系建模。

本文没有直接将完整 128000 点序列输入注意力层,原因在于标准注意力的计算复杂度过高。若序列长度为 L ,注意力矩阵大小为 $L \times L$,计算和存储成本均随 L^2 增长。对于本文的原始序列长度,直接计算注意力几乎不可行。因此,模型先通过卷积前端完成时间维度压缩,再在压缩后的特征序列上进行注意力计算。这一过程与基础 CNN 的设计逻辑一致:先从原始高采样率波形中提取较低分辨率但更抽象的特征,再在高层特征空间中进行任务相关判断。

从分类任务角度看,Conformer 的优势更容易发挥。五分类任务关注的是不同泄漏形态和正常状态之间的整体差异,模型只要捕获到足够稳定的判别模式,就能在类别空间中形成清晰边界。自注意力能够利用同一窗口内多个时间区域

之间的互相支持关系，从而减少局部噪声片段对单次预测的影响。本文实验中 Conformer 在 Stage2 上显著提升片段级 Accuracy 和 Macro-F1，说明分类任务确实受益于更强的上下文建模。

但对于距离回归任务，Conformer 的优势并不必然成立。距离估计依赖的是左右通道之间较细微的传播差异，而这些差异可能被强模型在全局池化或注意力加权过程中部分平滑掉。另一方面，回归样本数量少于分类样本，距离档位分布也不均衡，复杂模型更容易学习到训练集中的偶然模式而不是稳定的物理规律。因此，本文将 Conformer 定位为结构对比实验，而不是默认替代基础 CNN 的最终模型。其结果有助于说明：模型容量增加并不等价于回归定位性能提升，任务性质、样本规模和标签分布同样决定模型表现。

从实验设计角度看，Conformer 并不是替代基础 CNN 的唯一主模型，而是用于回答一个更具体的问题：更强的时序上下文建模是否能够在当前数据规模下带来稳定收益。后续实验结果表明，该结构在 Stage2 分类任务上显著提升片段级性能，但在 Stage1 距离回归任务上并未优于一维 CNN，说明分类识别和距离估计对模型结构的需求并不完全一致。

3.6 分类头与回归头设计

3.6.1 Stage2 分类模型

Stage2 分类任务使用单通道输入，模型主干输出全局特征后，经由两层全连接网络映射到五维类别空间，最终输出五类标签的预测结果。分类任务损失函数采用交叉熵损失，其表达式为：

$$\mathcal{L}_{cls} = - \sum_{c=1}^C y_c \log \hat{y}_c \quad (3-2)$$

其中， C 表示类别数量， y_c 为真实标签的 one-hot 编码， $\hat{y}_c$ 为模型输出的类别概率。

3.6.2 Stage1 回归模型

Stage1 回归任务使用双通道输入，模型输出单一实数作为泄漏距离预测值。与分类任务不同，回归任务不涉及 Softmax 归一化，全连接层直接输出连续数值。为增强对异常误差的鲁棒性，当前实现中优先采用 Smooth L1 损失：

$$\mathcal{L}_{reg}(d, \hat{d}) = \begin{cases} \frac{1}{2}(d - \hat{d})^2, & |d - \hat{d}| < 1 \\ |d - \hat{d}| - \frac{1}{2}, & |d - \hat{d}| \geq 1 \end{cases} \quad (3-3)$$

其中, d 为真实距离, $\hat{d}$ 为预测距离。相较于均方误差, Smooth L1 在误差较大时对离群点的敏感性更低, 有利于提升回归训练的稳定性。

3.7 训练策略

统一训练流程定义于 `src/leak_detection/training/trainer.py`。训练器按照“加载配置、构建数据加载器、创建模型与优化器、迭代训练、验证评估、测试输出”的流程执行。当前实验采用 AdamW 优化器^[12], 基础一维 CNN 的初始学习率为 0.001, Conformer 结构由于参数量更大、优化过程更敏感, 初始学习率设为 0.0005; 两类模型的权重衰减均为 0.0001, 并使用余弦退火学习率调度器对学习率进行平滑衰减。训练最大轮数设置为 40, 早停轮数设置为 8; 当验证集指标连续 8 轮未提升时, 训练提前终止, 并保留验证集表现最优的模型参数。

此外, 为避免梯度爆炸影响长时序训练稳定性, 训练过程中对梯度范数进行裁剪, 阈值为 1.0。分类任务以验证集准确率作为模型选择依据; 回归任务以验证集 MAE 作为主要选择指标, 并在测试阶段补充 RMSE、误差方向、容差命中率、最大误差、最小误差以及文件级聚合指标。训练完成后, 程序自动加载最佳验证模型, 并在测试集上输出最终指标。

3.8 正则化与过拟合抑制策略

在参数量较大而训练样本相对有限时, 深度学习模型容易出现过拟合, 即训练集表现较好但测试集泛化能力下降。为缓解这一问题, 本文从训练控制、参数约束和数据预处理三个层面设计正则化策略。

3.8.1 早停机制

早停是最简单有效的正则化手段之一。本文设定最大训练轮数为 40 轮, 并采用验证集指标监测机制: 若验证集指标连续 8 轮未出现改善, 则提前终止训练, 并恢复到验证集最优的模型参数。这一策略的出发点在于: 随着训练进行, 模型可能先学习到数据中的通用模式, 而后逐渐记忆训练集中的噪声和异常样本。早停能够在模型开始过拟合之前及时停止, 从而获得泛化能力更强的模型。

3.8.2 权重衰减

权重衰减 (Weight Decay) 等价于在损失函数中引入 L2 正则化项。设原损失函数为 $\mathcal{L}(\theta)$, 则加入权重衰减后的总损失为:

$$\tilde{\mathcal{L}}(\theta) = \mathcal{L}(\theta) + \frac{\lambda}{2} \|\theta\|_2^2 \quad (3-4)$$

其中 λ 为权重衰减系数，本文取 0.0001。该项约束迫使模型参数趋于较小值，从而降低模型对输入信号的敏感程度，减小决策边界的复杂度。在 AdamW 优化器^[12] 中，权重衰减与自适应学习率解耦，使得正则化效果更加稳定。

3.8.3 梯度裁剪

在长时序信号建模中，单个样本包含 128000 个采样点，网络需要经过多层卷积逐步降采样，梯度在反向传播过程中可能累积放大，导致梯度爆炸。本文采用全局梯度范数裁剪策略，设定裁剪阈值为 1.0。设 $\mathbf{g}$ 为所有参数的梯度向量，若 $\|\mathbf{g}\|_2 > 1.0$ ，则按比例缩放：

$$\mathbf{g} \leftarrow \frac{1.0}{\|\mathbf{g}\|_2} \cdot \mathbf{g} \quad (3-5)$$

该操作确保梯度范数始终不超过 1.0，有效防止了极端梯度更新对模型参数造成破坏性影响。

3.8.4 批归一化的正则化效应

批归一化虽然最初是为解决内部协变量偏移而提出的^[10]，但其本身也具备一定的正则化效果。在训练过程中，批归一化使用当前小批量的均值和方差对特征进行标准化，由于每个批量的统计量存在随机波动，相当于在特征空间中引入了轻微的扰动噪声。这种隐式正则化在一定程度上可以替代 Dropout 的作用。因此，本文在卷积模块中采用批归一化而非 Dropout，既简化了模型结构，又保持了足够的正则化能力。

3.8.5 数据层面的泛化保障

除模型层面的正则化外，本文在数据处理阶段也采取了泛化保障措施。每个分段样本在输入网络之前会进行逐段标准化处理，减去自身均值并除以标准差。该操作消去了不同样本之间的幅值差异，使网络更关注波形相对形态而非绝对幅值，从而增强了对不同实验条件下信号幅值变化的适应能力。此外，随机种子固定为 42，保证训练集、验证集与测试集划分在不同实验中保持一致，消除了数据划分随机性带来的结果波动。

第四章 实验设计与结果分析

4.1 实验环境与配置

本文实验基于 Python 与 PyTorch 深度学习框架完成,数据集构建与模型训练均通过命令行工具调用,实验流程具有较好的可复现性。当前项目提供基础 CNN 配置文件 `configs/stage2.yaml` 和 `configs/stage1.yaml`, 分别用于分类实验与回归实验;同时提供 `configs/stage2_conformer.yaml` 和 `configs/stage1_conformer.yaml`, 用于在相同数据划分下进行 Conformer 结构对比。不同配置主要区别体现在网络结构、输入形式、任务头、损失函数与评价指标上。

为保证不同实验之间具有可比性,本文固定随机种子为 42,并保持训练集、验证集和测试集划分一致。实验分析围绕四个层次展开:首先报告基础一维 CNN 在分类与回归任务上的结果;其次通过传统机器学习基线考察端到端深度模型相对于手工特征方法的优势与不足;再次通过 Conformer 结构对比分析更强时序上下文建模是否带来收益;最后通过通道数和损失函数等消融实验分析关键设计选择对性能的影响。这样的组织方式能够避免只给出单一模型结果,使实验结论更具有可解释性。

4.2 评价指标

4.2.1 分类任务指标

对于 Stage2 分类任务,本文采用准确率、macro-F1 和混淆矩阵作为主要评价指标。仅依赖准确率可能掩盖模型在少数类上的识别不足,因此引入 macro-F1 以更均衡地反映各类别性能。混淆矩阵用于展示不同类别之间的误分类模式,便于分析模型在哪些类别对之间容易发生混淆。准确率定义为:

$$Accuracy = \frac{N_{correct}}{N_{total}} \quad (4-1)$$

其中, $N_{correct}$ 表示预测正确的样本数量, N_{total} 表示测试样本总量。macro-F1 先分别计算每个类别的精确率 (Precision) 和召回率 (Recall), 由二者调和平均得到该类别的 F1 值,再对各类别结果进行等权平均。由于 macro-F1 不对多数类赋予更高权重,因此更适合用于观察类别不均衡条件下的分类效果。此外,本文同时统计片段级混淆矩阵与原始文件级混淆矩阵,用于分析不同评测层级下的误分类关系。

在实际泄漏检测场景中，片段级指标和文件级指标具有不同含义。片段级指标衡量模型对单个 5 s 时间窗口的直接判断能力，反映模型在局部观测条件下的鲁棒性；文件级指标则更接近工程应用中的最终报警决策，因为实际系统通常会连续采集多个时间窗口，不会仅凭一个短窗口立即做出最终判断。因此，当片段级指标存在少量波动时，文件级聚合仍可能给出稳定结果。本文同时报告这两类指标，是为了区分模型的瞬时判别能力和完整采样记录下的综合判断能力。

混淆矩阵相比单一数值指标具有更强的诊断作用。若模型在所有类别上随机出错，说明特征表示整体不足；若误差集中在少数类别对之间，则说明这些类别在当前信号空间中存在相似模式，后续可以针对性地补充样本或改进特征提取方式。例如，若某一泄漏形态经常被误判为另一形态，可能说明二者在局部波形或频域能量分布上接近；若泄漏类别被误判为正常类别，则更需要关注漏报风险。因此，本文在结果分析中不仅报告 Accuracy 和 Macro-F1，也结合混淆矩阵讨论误差来源。

4.2.2 回归任务指标

对于 Stage1 回归任务，本文采用平均绝对误差与均方根误差作为主要指标，分别表示为：

$$MAE = \frac{1}{N} \sum_{i=1}^N |d_i - \hat{d}_i| \quad (4-2)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (d_i - \hat{d}_i)^2} \quad (4-3)$$

其中， d_i 为真实距离， $\hat{d}_i$ 为预测距离。MAE 反映平均偏差水平，RMSE 对较大误差更加敏感，二者结合能够较全面地反映定位性能。

为增强回归结果的物理可解释性，本文进一步统计有符号误差 $e_i = \hat{d}_i - d_i$ 、最大绝对误差、最小绝对误差以及容差命中率。容差命中率定义为：

$$Acc_\tau = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(|\hat{d}_i - d_i| \leq \tau) \quad (4-4)$$

其中， τ 表示允许误差阈值。本文重点报告 $\tau = 1.0$ 时的结果，用于衡量预测值是否落在真实距离附近一个单位范围内。由于同一原始文件会被切分为多个片段，本文还对同一原始文件下的片段预测结果求平均，得到文件级距离预测，并计算对应的文件级 MAE、RMSE 和最大误差。

对于距离回归任务，只报告 MAE 和 RMSE 仍然不够。MAE 可以反映平均

偏差，但无法区分误差方向；RMSE 对大误差敏感，但不能说明错误主要集中在哪些距离档位。因此，本文进一步统计 Bias、P95 绝对误差、容差命中率和按距离档位划分的误差。Bias 用于判断模型是否存在系统性高估或低估；P95 绝对误差用于观察极端误差范围；容差命中率则更接近工程可接受误差的概念。若某一模型 MAE 较低但大误差样本很多，则在实际定位中仍可能不可靠；反之，如果模型在关键距离范围内具有较高容差命中率，即使总体 MAE 不占优势，也可能具有一定应用价值。

文件级回归指标的解释也需要谨慎。分类任务中，多片段聚合通常可以提高稳定性；但回归任务中，简单平均并不必然降低误差。如果同一文件内多个片段的预测偏差方向一致，平均后仍会保留系统性偏差；如果不同片段质量差异较大，低质量片段还可能拉偏文件级结果。因此，本文将文件级回归结果作为辅助指标，并在结果分析中讨论片段聚合策略的局限性。后续若要面向工程部署，可进一步引入片段置信度、预测方差或异常片段剔除机制，使文件级距离估计更加稳健。

4.3 实验结果

本文首先对 Stage2 分类任务进行训练与测试，并从片段级和文件级两个层面报告实验结果。片段级评测反映模型对单个 5 秒窗口的直接判别能力，文件级评测则将同一原始实验文件下的多个片段预测进行聚合，更接近实际应用中一段完整采样记录做最终判断的使用方式。在完成泄漏状态识别后，Stage1 回归任务进一步对泄漏样本进行距离估计，用于分析双通道信号中是否包含可学习的定位信息。

4.3.1 Stage2 分类结果

Stage2 任务为五分类任务。模型在第 20 轮触发早停，最佳验证集准确率为 0.9968。测试集结果如表4-1所示：片段级 Accuracy 为 0.9415，片段级 Macro-F1 为 0.9180；将同一原始文件下的多个片段按平均 logits 聚合后，文件级 Accuracy 提升至 0.9783，文件级 Macro-F1 为 0.9836。

从指标含义上看，片段级 Accuracy 反映整体预测正确比例，Macro-F1 则对每个类别赋予相同权重，因此能够更直接地反映少数类的识别情况。当前片段级 Macro-F1 低于 Accuracy，说明模型在部分类别上的召回率或精确率仍存在波动。文件级聚合后两项指标均明显提升，说明单个片段中的偶发误判并不一定会导致整段实验文件的最终判断错误。

从混淆矩阵可以看出，类别 0、类别 3 和类别 4 的识别较为稳定，其中类别

表 4-1 Stage2 分类任务测试结果

评测层级	指标	数值
片段级	Accuracy	0.9415
片段级	Macro-F1	0.9180
文件级	Accuracy	0.9783
文件级	Macro-F1	0.9836

表 4-2 Stage2 分类任务传统基线对比

方法	片段级 Accuracy	片段级 Macro-F1	文件级 Accuracy	文件级 Macro-F1
一维 CNN	0.9415	0.9180	0.9783	0.9836
SVM	0.9300	0.9046	1.0000	1.0000
KNN	0.9277	0.9155	0.9783	0.9751
决策树	0.8738	0.8309	0.9565	0.9600




图 4-1 Stage2 分类任务混淆矩阵（左：片段级；右：文件级）

4 在测试集中全部被正确识别。主要误差集中在类别 1 与类别 3、类别 2 与类别 0/1 之间：片段级测试中，类别 1 有 31 个片段被误判为类别 3，类别 2 有 15 个片段被误判为类别 0、27 个片段被误判为类别 1。文件级聚合后误差明显减少，46 个测试文件中仅 1 个类别 2 文件被判为类别 0，说明多片段聚合能够有效削弱单个片段的预测波动。

类别 1 与类别 3 之间的混淆可能与两类泄漏形态在局部波形上的相似性有关。对于单个 5 秒窗口而言，模型只能利用该窗口内部的局部振动特征进行判别；若窗口中泄漏信号响应较弱、噪声占比较高，或该窗口恰好位于信号状态变化不明显的时段，模型就更容易将其判为相邻形态。类别 2 被误判为类别 0 或类别 1 的现象则说明该类别内部可能存在更强的样本差异，一部分片段与正常状态或其他泄漏形态在特征空间中距离较近。后续可以从两个方向改善这一问题：一是增加类别 2 相关样本或采用类别重加权策略，二是在推理阶段优先采用文件级聚合结果，而不是只依赖单个片段判断。




图 4-2 Stage2 分类任务训练过程曲线（左：损失曲线；右：准确率曲线）

4.3.2 Stage1 距离回归结果

Stage1 任务采用左右双通道输入进行距离回归。该阶段只对泄漏样本进行建模，目标是从左右通道之间的幅值差异、时序响应差异和局部波形变化中估计泄漏距离。与分类任务相比，距离回归对信号细节更加敏感：相邻距离档位之间的波形差异可能较小，而噪声、局部扰动和样本分布不均衡都会放大预测偏差。因此，本文除 MAE 和 RMSE 外，还结合误差方向、容差命中率、按距离档位拆分结果和文件级聚合结果进行分析。

模型在第 27 轮获得最佳验证集 MAE (约 1.90)，随后进入早停。测试集结果如表 4-3 所示：片段级 MAE 为 1.90，RMSE 为 2.43；文件级 MAE 为 2.46，RMSE 为 2.94。片段级 R^2 为 0.54，说明模型已经学习到一定的距离相关特征，但定位误差仍不可忽略，尤其需要结合不同距离档位上的表现进一步判断其适用范围。

表 4-3 Stage1 回归任务测试结果

评测层级	指标	测试集
片段级	MAE	1.90
片段级	RMSE	2.43
文件级	MAE	2.46
文件级	RMSE	2.94

表 4-4 Stage1 回归任务传统基线对比

方法	片段级			文件级		
	MAE	RMSE	误差 ≤ 1.0	MAE	RMSE	误差 ≤ 1.0
一维 CNN	1.90	2.43	0.35	2.46	2.94	0.25
SVM	1.51	1.91	0.46	1.83	2.20	0.38
KNN	1.76	2.29	0.44	2.02	2.43	0.28
决策树	2.44	2.97	0.34	2.23	2.58	0.28

表 4-5 Stage1 回归任务通道消融实验

设置	片段级			文件级		
	MAE	RMSE	误差 ≤ 1.0	MAE	RMSE	误差 ≤ 1.0
双通道输入（默认）	1.90	2.43	0.35	2.46	2.94	0.25
单通道输入	3.88	4.75	0.17	3.17	3.95	0.16

表 4-6 一维 CNN 与 Conformer 结构对比

任务	模型	片段主指标	片段辅指标	文件主指标	文件辅指标
Stage2 分类	一维 CNN	Acc 0.9415	Macro-F1 0.9180	Acc 0.9783	Macro-F1 0.9836
Stage2 分类	Conformer	Acc 0.9900	Macro-F1 0.9883	Acc 1.0000	Macro-F1 1.0000
Stage1 回归	一维 CNN	MAE 1.90	RMSE 2.43	MAE 2.46	RMSE 2.94
Stage1 回归	Conformer	MAE 1.95	RMSE 2.63	MAE 2.51	RMSE 3.10

表 4-7 Stage1 回归任务物理误差分析

指标	片段级	文件级
MAE	1.90	2.46
RMSE	2.43	2.94
中位绝对误差	1.45	2.14
P95 绝对误差	4.99	5.15
最大绝对误差	6.86	5.65
R^2	0.54	0.30
误差 ≤ 0.5 占比	0.15	0.13
误差 ≤ 1.0 占比	0.35	0.25
误差 ≤ 2.0 占比	0.66	0.44
有符号偏差 (Bias)	+0.45	+0.91
四舍五入精确命中	0.15	—

表 4-8 Stage1 回归任务按距离档位误差（片段级）

真实距离 (m)	样本数	MAE	RMSE	Bias	误差 ≤ 1.0 占比	文件级 MAE
-3	118	2.83	3.28	+2.66	0.13	3.29
-1	23	4.85	4.86	+4.85	0.00	4.85
0	69	0.67	0.83	+0.23	0.74	0.23
+1	46	2.14	2.32	-2.14	0.09	2.14
+3	53	2.44	2.66	-1.21	0.08	2.92
+5	46	1.24	1.32	-1.24	0.37	1.24
+6	46	0.61	0.74	+0.48	0.85	0.48
+7	46	0.95	1.04	-0.95	0.61	0.95

表 4-9 两阶段任务主要实验结果汇总

任务	主要指标	辅助指标	备注
Stage2 分类	Acc = 0.9415	Macro-F1 = 0.9180	文件级 Acc = 0.9783
Stage1 回归	MAE = 1.90 m	RMSE = 2.43 m	文件级 MAE = 2.46 m




图 4-3 Stage1 回归任务误差可视化（左：片段级预测值与真实值散点图；右：片段级不同距离档位的绝对误差分布）




图 4-4 Stage1 回归任务片段级预测误差分布直方图




图 4-5 Stage1 回归任务训练过程曲线（左：损失曲线；右：MAE 曲线）

4.4 结果分析

4.4.1 Stage2 分类结果分析

当前 Stage2 实验表明，一维卷积模型能够在五分类设置下取得较高的文件级识别性能。片段级指标低于文件级指标，说明单个 5 秒片段仍可能受到局部噪声、信号过渡状态或类别间波形相似性的影响；而文件级聚合能够利用同一原始文件中的多片段信息，提升最终判别稳定性。这一现象也说明，在实际部署时，不宜仅根据单个短窗口直接给出最终结论，而应在时间维度上积累多个窗口的预测结果，再通过平均 logits、投票或置信度加权等方式形成更稳健的文件级或时间段级判断。Conformer 结构进一步提升了片段级分类指标，说明分类任务确实能够从更强的上下文建模中受益。

从错误分布看，模型并非在所有类别上均匀出错，而是集中出现在少数类别对之间。这类结构化误差比随机误差更具有分析价值：它提示不同泄漏形态之间可能存在部分共享的波形特征，也提示当前模型在特征空间中对某些类别边界的刻画仍不够充分。若后续需要进一步提升片段级指标，可以考虑引入类别均衡采样、类别权重交叉熵、困难样本重采样，或在模型结构中增加多尺度卷积模块，使网络同时关注短时冲击特征和较长时间范围内的能量变化。

此外，当前实验结果也体现了两阶段框架的工程意义。分类阶段的目标不是单纯追求片段级绝对准确，而是为后续距离估计提供可靠的泄漏样本筛选。如果文件级分类结果足够稳定，那么系统可以在较低误报率的基础上触发第二阶段定位模型，从而减少对正常样本进行无意义回归计算的情况。

4.4.2 Stage1 回归结果分析

从总体指标看，Stage1 回归模型在测试集上取得片段级 MAE 1.90 m、RMSE 2.43 m 的距离估计精度。考虑到本文仅使用原始波形信号进行端到端学习而未引入任何物理先验或手工特征，该结果验证了卷积网络从双通道信号中学习距离映射的可行性。然而，当前误差水平距离精确工程定位仍有差距，特别是在大误差区域（P95 绝对误差达 4.99 m），模型对部分样本的距离预测偏差较大。与 Stage2 不同，Conformer 在该任务上没有带来误差下降，说明距离回归更受样本规模、距离档位分布和信号细粒度差异制约。

Bias 指标（平均有符号误差 +0.45 m）整体偏正，但不同距离区间表现出不同方向的偏差模式。距离 0 m 和 +6 m 的误差最小（MAE 分别为 0.67 m 和 0.61 m，容差 1.0 m 命中率分别为 74% 和 85%），这两个距离上的信号特征可能与其他距离存在明显差异，模型能够较好地将其与其他距离区分。距离 -3 m 和 -1

m 的预测值均存在较强的正向偏差（Bias 分别为 +2.66 m 和 +4.85 m），即模型倾向于将这些负向距离预测向 0 方向拉近；正距离部分的样本中，+1 m 和 +5 m 的预测值则存在明显的负向偏差（Bias 分别为 -2.14 m 和 -1.24 m），表现出预测向中间值压缩的回归到均值现象。这种“两端向中间靠拢”的偏差模式是回归模型在小样本条件下的常见现象：当某些距离档位样本数量较少或信号特征区分度不足时，模型倾向于输出靠近训练集均值附近的预测值，以减少平均损失但牺牲了对极端值的区分能力。

从片段级与文件级指标对比来看，文件级 MAE 略高于片段级 MAE（2.46 m vs 1.90 m），这与分类任务中文件级指标普遍优于片段级的现象相反。造成这一差异的可能原因是：同一原始文件内的不同片段可能具有不同的预测方向偏差，单独片段的误差通过绝对值计算后可能偏低，而文件级平均后偏差方向趋于一致、反而增大了绝对误差。这提示在距离回归任务中，简单取片段预测值平均不一定是最优的聚合策略，后续可探索按片段置信度加权或基于片段误差方差的融合策略。

从工程应用角度看，当前回归性能在不同距离档位上分化明显。距离 0 和 +6 的定位精度已达到较好水平（误差 ≤ 1 m 占比超 74%），可作为中置信度判断的依据；但部分困难距离（-3、-1、+1、+3）的误差仍较大。若将该模型部署于实际场景，建议优先将距离估计与分类置信度结合使用，对低置信度片段附加不确定性提示，同时通过增加各距离档位的训练样本和引入距离感知的特征增强来缓解误差不均匀问题。

4.4.3 对比实验与消融实验分析

仅报告主模型结果不足以说明模型设计的必要性，因此本文进一步设置传统机器学习基线和关键模块消融实验。传统基线采用时域统计特征、频域能量特征等手工特征，并分别训练支持向量机、K 近邻和决策树模型。该组实验用于回答“端到端一维卷积网络相对于手工特征方法是否具有稳定优势”这一问题。实验结果显示，两类任务中的传统基线均具有较强竞争力，说明当前数据集在统计特征和频域特征层面已经包含较明显的判别信息。

消融实验主要关注两个设计选择。第一是输入通道数。对于 Stage1 回归任务，双通道输入具有明确物理意义，因为泄漏位置会影响左右传感通道的响应差异；若单通道模型性能明显下降，则可以证明通道间差异对定位任务是有效信息。表4-5给出了当前已完成的通道消融结果：当回归模型由双通道输入退化为单通道输入后，片段级 MAE 由 1.90 m 增大到 3.88 m，RMSE 由 2.43 m 增大到 4.75 m，误差不超过 1.0 m 的比例也由 0.35 降至 0.17；文件级 MAE 同样由 2.46 m 增大到 3.17 m。该结果说明，仅依赖单侧传感信号难以稳定恢复泄漏距离，左

右通道之间的响应差异确实是距离估计的重要信息来源。对于 Stage2 分类任务，单通道输入是当前主设置，双通道消融则可用于判断分类任务是否同样受益于通道联合建模。第二是回归损失函数。Smooth L1 损失在小误差区域接近 MSE、在大误差区域接近 MAE，理论上对异常误差更稳健；将其与 MSE 对比，可以验证当前距离回归任务中是否存在对大误差较敏感的训练现象。

从 Stage2 分类结果看，一维 CNN 在片段级 Accuracy 和 Macro-F1 上略高于 SVM，说明端到端波形特征学习对单片段判别具有一定收益。但在文件级聚合后，SVM 达到 1.0000 的 Accuracy 和 Macro-F1，KNN 也取得与 CNN 相同的文件级 Accuracy。这说明当前分类任务在文件级上具有较强可分性，多片段聚合后传统手工特征方法也能够形成稳定判断。因此，Stage2 的主要结论不应表述为深度模型全面优于传统方法，而应表述为：一维 CNN 在片段级建模上具有一定优势，而文件级聚合能够显著提升不同方法的稳定性。

从 Stage1 回归结果看，SVM 基线在片段级和文件级指标上均优于当前一维 CNN。SVM 的片段级 MAE 为 1.51，低于 CNN 的 1.90；文件级 MAE 为 1.83，也低于 CNN 的 2.46。这一结果说明，在当前样本规模和距离分布条件下，固定手工特征结合核方法能够更稳定地拟合距离映射；而端到端 CNN 虽然验证了从双通道原始波形中学习距离信息的可行性，但尚未在回归任务上超过强传统基线。该现象也提示后续模型优化应重点围绕数据规模、距离均衡、时频联合特征和更强时序结构展开，而不是简单增大卷积网络容量。

进一步地，本文补充了 Conformer 结构对比实验，结果如表4-6所示。对于 Stage2 分类任务，Conformer 将片段级 Accuracy 从 0.9415 提升至 0.9900，Macro-F1 从 0.9180 提升至 0.9883，文件级 Accuracy 和 Macro-F1 均达到 1.0000，说明引入局部卷积与自注意力结合的时序建模结构能够更充分地捕获分类任务中的全局上下文信息。对于 Stage1 回归任务，Conformer 的片段级 MAE 为 1.95 m、RMSE 为 2.63 m，文件级 MAE 为 2.51 m、RMSE 为 3.10 m，略差于一维 CNN。该结果表明，更复杂的时序结构并不必然改善距离回归性能；在当前回归样本规模和距离档位分布下，模型容量增大可能带来更高的优化难度和过拟合风险。

从论文组织角度看，基线实验、结构对比和消融实验不应独立堆放，而应服务于主结论。传统基线揭示了手工特征方法在当前数据上的竞争力，Conformer 对比说明注意力结构对分类任务更有效但未解决回归定位问题，通道消融则用于判断双通道定位建模是否必要。综合这些结果可以看出，本文方法在分类识别上已经具备较强性能，而距离回归仍是后续优化的重点。

4.4.4 训练过程分析

从训练过程曲线可以看出，训练集与验证集的损失和 MAE 在初期快速下降后逐步趋缓。验证集曲线在部分轮次呈现较明显的波动（尤其在第 5 和第 9 轮附近出现异常毛刺），这可能与验证集中部分距离档位的样本量较少导致的批间评估方差较大有关。受益于余弦退火学习率调度，模型在训练中后期持续以较小的学习率在优化空间中进行精细搜索，训练损失从第 15 轮后呈现出更加平滑的下降趋势。验证集曲线波动与训练集曲线之间的差距在后期有所收敛，但整体仍存在一定差距，说明模型在当前数据规模和网络容量下存在一定程度的过拟合，但通过早停机制和 dropout 正则化得到了部分抑制。

第五章 结论与展望

5.1 全文总结

本文围绕双通道管道传感信号的泄漏检测与定位问题，完成了从数据构建、任务拆解到模型设计与实验验证的研究流程。主要工作可概括为以下几个方面：

第一，构建了从原始 CSV 信号到训练样本的自动化处理流程。当前训练样本由数据清单和分段切片文件统一管理，分类任务为五分类设置，回归任务使用左右双通道信号进行距离估计。该流程将原始数据读取、标签映射、文件级划分、固定窗口切分和清单生成组织为可复现的数据处理链路，为后续训练与分析提供了稳定输入。

第二，设计了两阶段泄漏检测框架，将复杂的泄漏检测与定位问题拆分为“先分类、后定位”的子任务序列。Stage2 分类任务以单通道分段信号为输入，完成正常状态与多类泄漏形态识别；Stage1 回归任务以左右双通道信号对为输入，完成泄漏距离估计。模型结构上，本文以一维卷积网络作为基础方案，并进一步接入 Conformer 结构进行对比，从而分析局部卷积建模与卷积-注意力混合建模在分类和回归任务中的适用差异。

第三，搭建了统一的训练框架与多维度评测体系。训练框架通过配置文件区分任务类型、数据集和网络结构，支持分类与回归任务的统一调度与灵活扩展。在评价指标方面，分类任务报告片段级与文件级准确率、macro-F1 和混淆矩阵；回归任务报告 MAE、RMSE、误差方向、容差命中率、按距离档位拆分误差和文件级聚合误差。同时，本文引入传统机器学习基线、CNN-Conformer 结构对比和关键模块消融实验，用于说明端到端建模、双通道输入和模型结构选择的合理性。多层次指标与对比实验相结合，能够避免单一平均值掩盖模型行为差异，使实验分析更加完整。

Stage2 五分类任务在测试集上取得片段级 Accuracy 0.9415、Macro-F1 0.9180，文件级 Accuracy 0.9783、Macro-F1 0.9836。结果表明，分类模型已经能够较稳定地区分正常状态与多类泄漏形态，尤其是在文件级聚合评测下表现更为稳健。传统基线对比显示，SVM 在文件级聚合后达到 1.0000 的 Accuracy 和 Macro-F1，说明当前分类数据在文件级上具有较强可分性，手工特征方法同样具有较高实用价值。进一步的结构对比显示，Conformer 在 Stage2 上取得片段级 Accuracy 0.9900、Macro-F1 0.9883，文件级 Accuracy 和 Macro-F1 均达到 1.0000，说明更强的时序上下文建模能够进一步提升分类任务的片段级稳定性。Stage1 回归任务在测试集上取得片段级 MAE 1.90 m、RMSE 2.43 m，文件级 MAE 2.46 m。

按距离档位拆分后, 部分距离 (0 m 和 +6 m) 的误差 ≤ 1 m 占比超过 74%, 验证了从双通道原始波形中端到端学习距离映射的可行性; 但与传统基线和 Conformer 对比结果相比, 距离回归仍未因模型结构复杂化而稳定改善, 提示在小样本和特征区分度不足的条件, 回归定位仍是一个具有挑战性的问题。

5.2 后续工作展望

尽管本文已经完成两阶段泄漏检测方法的基本实现与实验验证, 但仍有若干方向值得进一步研究:

1. 在数据层面, 当前数据规模仍有进一步扩展空间。特别是距离回归任务中, 不同距离档位的样本分布不均衡 (如 -1 m 仅 23 个片段), 导致模型在少数距离上学习不充分, 出现了明显的“回归到均值”偏差。后续可补充不同压力、流量、管径、传感器安装位置和环境噪声条件下的样本, 并对样本不足的距离档位进行针对性扩充, 使训练集覆盖更多实际工况。对于分类任务中容易混淆的类别, 还可以采用更严格的分层划分方式或类别重加权策略。
2. 在模型层面, 当前一维卷积网络结构较为简洁, 优点是训练稳定、参数量可控、易于复现。Conformer 实验表明, 注意力结构能够提升分类任务的片段级性能, 但并未改善距离回归误差。因此, 后续模型优化不宜只依赖扩大模型容量, 而应结合回归任务特点引入距离感知损失、样本均衡策略、多尺度时频特征或不确定性估计, 使模型更好地区分相邻距离档位。
3. 在任务层面, 当前分类与回归任务使用独立的模型和训练流程。这种方式模块清晰、便于调试, 但两个阶段之间的信息传递相对简单。后续可考虑将两阶段设计为端到端的联合学习框架, 探索共享底层特征表示是否能够进一步提升整体性能。同时, 对分类阶段已识别的泄漏样本, 还可引入更精细的泄漏形态子分类, 为后续维护决策提供更多信息。
4. 在评测层面, 除常规随机划分外, 还可设计更严格的跨批次、跨工况或跨实验条件验证。尤其对于管道泄漏检测任务, 模型在同一实验条件下取得较好结果并不必然意味着能够适应真实现场环境。因此, 后续应重点关注模型在未知噪声、未知泄漏强度和未知传感器安装条件下的泛化表现。
5. 在应用层面, 当前模型参数量和推理速度能够满足离线实验分析需求, 但距离实时在线检测仍有差距。后续可围绕模型轻量化 (如知识蒸馏、网络剪枝、量化部署) 和边缘端推理展开研究。此外, 还可探索在线增量学习机制, 使模型在部署后持续适应新的工况变化, 减少对离线批量训练的依赖。

总体而言，本文围绕“数据构建—任务拆解—模型设计—实验验证”四个环节，完成了一套面向双通道传感信号的两阶段管道泄漏检测与定位方案。在当前数据集与实验条件下，该方案在分类任务上取得了较高识别性能，在回归任务上验证了从双通道分段波形中学习距离映射的可行性。与此同时，传统基线实验表明，手工特征结合 SVM 在文件级分类和距离回归中仍具有很强竞争力，尤其在 Stage1 回归任务上优于当前 CNN 模型；Conformer 结构对比则表明，注意力结构能够明显提升 Stage2 分类性能，但未能改善 Stage1 距离回归误差。因此，本文结论更加侧重于两阶段框架和端到端建模的可行性验证，而非声称深度模型在所有指标上全面领先。后续仍需要在数据覆盖、模型结构、时频特征融合和聚合策略上进一步优化。上述结果为基于分段时序信号开展管道泄漏检测与定位提供了实验依据，也为后续更广泛工况验证、模型优化和工程部署奠定了基础。

参考文献

- [1] Li J, Zheng Q, Li Z, et al. Pipeline leak detection: A comprehensive review of methods and technologies [J]. Measurement, 2023, 198: 111–125.
- [2] Sharma A, Kumar V, Gupta R. Pipeline leak localization using acoustic emission and machine learning: A review [J]. Process Safety and Environmental Protection, 2022, 158: 531–548.
- [3] Kıymık M K, Güler I, Dizibüyük A, et al. Comparison of STFT and wavelet transform methods in determining epileptic seizure activity in EEG signals for real-time application [J]. Computers in biology and medicine, 2005, 35 (7): 603–616.
- [4] Chen X, Wang J, Liu Y. SVM-based pipeline leak detection with feature extraction from acoustic signals [J]. IEEE Sensors Journal, 2020, 20 (16): 9450–9461.
- [5] 周志华. 机器学习 [M]. 北京: 清华大学出版社, 2016: 181–185.
- [6] Wang Z, Oates T, et al. Deep learning for time series signal analysis: A survey [J]. Information Fusion, 2022, 77: 145–167.
- [7] Goodfellow I, Bengio Y, Courville A. Deep learning [M]. MIT Press, 2016.
- [8] Kiranyaz S, Avci O, Abdeljaber O, et al. 1D convolutional neural networks and applications: A survey [J]. Mechanical Systems and Signal Processing, 2021, 151: 107–128.
- [9] Zhang Y, Chen S, Li W. A CNN-based pipeline leak detection method using acoustic signals [C]. In IEEE International Conference on Acoustics, Speech and Signal Processing, 2019: 2765–2769.
- [10] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift [C]. In International Conference on Machine Learning, 2015: 448–456.
- [11] Hendrycks D, Gimpel K. Gaussian error linear units (GELUs) [J]. arXiv preprint arXiv:1606.08415, 2016.
- [12] Loshchilov I, Hutter F. Decoupled weight decay regularization [C]. In International Conference on Learning Representations, 2019.

- [13] 李晟洁, 李翔, 张越, 等. 基于 Wi-Fi 信道状态信息的行走识别与行走参数估计 [J]. 软件学报, 2021, 32 (10): 3122–3138.
- [14] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets [J]. Advances in Neural Information Processing Systems, 2014, 27.

致 谢

本论文的完成得益于多位老师和同学的帮助与支持，在此谨向他们表示诚挚的感谢。

首先，衷心感谢我的指导老师。在毕业设计期间，老师在选题方向、技术路线和研究方法上给予了充分的指导和支持，耐心解答了我在研究过程中遇到的各种问题，并在论文撰写阶段提出了许多宝贵的修改意见。老师严谨的治学态度和扎实的专业素养让我受益匪浅。

其次，感谢实验室的各位同学。他们在日常科研讨论中分享了许多有价值的思路和方法，在实验实施和数据分析过程中也提供了不少帮助。与他们的交流和协作使我的研究工作更加顺利。

感谢天津大学建筑工程学院四年来的培养。学院提供的良好学习环境和科研平台为本文研究的顺利开展提供了基础保障。

最后，感谢我的家人和朋友在学业期间给予的理解、鼓励和支持。他们的关心是我能够顺利完成学业的重要动力。