

天津大学

本科生毕业论文



题目：基于双通道时序信号的两阶段管道泄漏检测与定位方法

学 院	建筑工程学院
专 业	船舶与海洋工程
年 级	2022 级
姓 名	孟达
学 号	3022205024
指导教师	顾鹏

摘 要

针对管道输送系统中泄漏状态识别困难、人工特征设计依赖较强以及泄漏距离估计精度不足等问题,本文围绕双通道时序传感信号,研究了一种基于深度学习的两阶段管道泄漏检测与定位方法。首先,结合泄漏声信号形成机制与双通道传播差异,构建从原始 CSV 采样数据到训练样本的自动化处理流程,将长时序双通道信号按照固定时间窗口切分为分段样本,并分别生成分类任务与回归任务所需的数据清单。其次,面向泄漏状态识别与泄漏距离估计两个目标,设计统一的一维卷积神经网络框架。其中,分类阶段(Stage2)以单通道分段信号为输入,用于识别正常状态与两类泄漏形态;回归阶段(Stage1)以左右双通道信号对为输入,用于估计泄漏距离。最后,基于统一训练框架完成模型训练、验证与测试,并从片段级与原始文件级两个层面评价分类性能,同时采用平均绝对误差、均方根误差、容差命中率、误差方向和按距离档位拆分误差分析距离估计效果。实验结果表明,在当前随机文件级划分下,本文方法在分类任务上取得了较高识别性能,测试集片段级准确率达到 0.9968,片段级 macro-F1 达到 0.9972,按原始文件聚合后的文件级准确率与文件级 macro-F1 均达到 1.0000;在距离回归任务上,测试集平均绝对误差为 0.3703,均方根误差为 0.5934,误差不超过 1 个距离单位的片段比例为 0.9286,文件级聚合后平均绝对误差进一步降至 0.2534。上述结果说明,本文提出的两阶段方法能够有效完成管道泄漏状态识别与距离估计任务,并为后续开展更严格的泛化验证与工程部署提供实验基础。

关键词: 管道泄漏检测, 时序信号分析, 深度学习, 一维卷积神经网络, 距离回归

ABSTRACT

To address the difficulty of leak state recognition, the strong dependence on hand-crafted features, and the insufficient accuracy of leak distance estimation in pipeline transport systems, this thesis studies a two-stage pipeline leak detection and localization method based on dual-channel time-series sensor signals. First, considering the generation mechanism of leakage acoustic signals and the propagation differences between two sensing channels, an automated data processing pipeline is constructed from raw CSV measurements. Long dual-channel signals are segmented with a fixed time window to generate structured samples for both classification and regression tasks. Second, a unified one-dimensional convolutional neural network framework is designed for leak state recognition and distance estimation. In the classification stage (Stage2), segmented single-channel signals are used to identify normal states and two leak patterns. In the regression stage (Stage1), paired left-right channel signals are used to estimate leak distance. Finally, a unified training framework is employed for model optimization, validation, and testing. Classification performance is evaluated at both the segment level and the original-file level, while distance estimation performance is measured by mean absolute error, root mean square error, tolerance accuracy, signed error, and distance-wise error analysis. Experimental results show that, under the current random file-level split, the proposed method achieves strong performance on the classification task, with a segment-level accuracy of 0.9968, a segment-level macro-F1 of 0.9972, and both file-level accuracy and file-level macro-F1 reaching 1.0000 on the test set. On the distance regression task, the test mean absolute error is 0.3703, the root mean square error is 0.5934, the proportion of segment-level predictions within one distance unit is 0.9286, and the file-level mean absolute error is further reduced to 0.2534 after aggregating segments from the same original file. These results indicate that the proposed two-stage method can effectively accomplish both leak state recognition and distance estimation, and provide an experimental basis for stricter generalization evaluation and engineering deployment.

KEY WORDS: Pipeline Leak Detection, Time-series Signal Analysis, Deep Learning, One-dimensional Convolutional Neural Network, Distance Regression

目 录

第一章	绪论	1
1.1	研究背景与意义	1
1.2	国内外研究现状	1
1.2.1	传统管道泄漏检测方法	1
1.2.2	基于机器学习的检测方法	2
1.2.3	基于深度学习的时序信号处理方法	2
1.2.4	深度学习在时序信号处理中的基础理论	3
1.3	研究问题与本文工作	3
1.4	论文结构安排	4
第二章	管道泄漏探测原理与数据集构建	5
2.1	管道泄漏探测基本原理	5
2.2	泄漏声信号形成机制	5
2.3	数据特征分析与建模需求	6
2.4	原始数据组织方式	6
2.5	标签映射与任务拆分	6
2.6	分段策略与样本生成	7
2.7	数据集统计	7
2.8	相关损失函数与优化理论	8
2.8.1	交叉熵损失与分类任务优化	8
2.8.2	Smooth L1 损失与距离回归任务优化	8
2.8.3	AdamW 优化器与余弦退火调度	9

第三章	两阶段泄漏检测模型设计	10
3.1	方法基础	10
3.2	总体框架	10
3.3	输入表示与归一化	11
3.4	一维卷积特征提取网络	11
3.5	分类头与回归头设计	12
3.5.1	Stage2 分类模型	12
3.5.2	Stage1 回归模型	12
3.6	训练策略	12
3.7	正则化与过拟合抑制策略	13
3.7.1	早停机制	13
3.7.2	权重衰减	13
3.7.3	梯度裁剪	13
3.7.4	批归一化的正则化效应	14
3.7.5	数据层面的泛化保障	14
第四章	实验设计与结果分析	15
4.1	实验环境与配置	15
4.2	评价指标	15
4.2.1	分类任务指标	15
4.2.2	回归任务指标	15
4.3	实验结果	16
4.3.1	Stage2 分类结果	16
4.3.2	Stage1 距离回归结果	17
4.4	结果分析	19

第五章	结论与展望	22
5.1	全文总结	22
5.2	后续工作展望	23
参考文献		24
致 谢		25

第一章 绪论

1.1 研究背景与意义

管道输送系统广泛应用于能源、化工与市政基础设施等场景，是现代社会能源供给与物资运输的重要支撑。管道一旦发生泄漏，不仅会造成介质损失和环境污染，严重时还可能引发火灾、爆炸等次生灾害。以油气管道为例，其输送距离长、沿线地质条件复杂，传统人工巡检和定期检修难以满足连续监测与快速定位的需求。因此，利用现代传感技术与智能数据分析方法，构建面向原始传感信号的自动泄漏识别与定位方法，具有明确的工程应用价值。

传统泄漏检测方法通常依赖人工经验、阈值规则或频域特征分析。在结构简单、噪声可控的场景下，这类方法能够发挥一定作用；但面对复杂工况、长时序原始信号以及不同泄漏形态时，仍存在特征设计依赖人工、泛化能力有限和定位精度不足等问题。随着深度学习在时序建模中的应用逐渐成熟，直接从原始信号中学习判别特征，为管道泄漏检测与定位提供了新的技术路径。

基于上述问题，本文围绕双通道管道传感信号，设计一种两阶段泄漏检测框架。该框架先对分段时序信号进行状态与泄漏形态识别，再对泄漏样本进行距离估计，从而将复杂任务拆分为“状态识别”和“位置估计”两个目标明确的子问题。这种分阶段处理方式有助于降低任务耦合度，提高训练过程的稳定性与结果解释的清晰度。

1.2 国内外研究现状

1.2.1 传统管道泄漏检测方法

在深度学习技术普及之前，工程实践中主要依赖物理模型与信号处理方法开展管道泄漏检测。声波法通过采集泄漏点产生的声发射信号，利用信号传播时间差和衰减特性推断泄漏位置，该方法在金属管道与高压场景下应用广泛^[1]。负压波法通过监测管道压力瞬时下降产生的负压波传播时间差实现泄漏定位，对于突发性大泄漏检测效果较好，但对微小渗漏反应不灵敏。此外，流量平衡法通过比对管道进出口流量差判断泄漏状态，此方法直观易实现，但受管道输送工况波动影响较大，难以单独完成精确定位^[2]。

上述传统方法在特定条件下均能发挥作用，但存在若干共性问题：首先，对信号质量要求较高，实际复杂噪声环境下容易发生误报或漏报；其次，检测阈值

和模型参数依赖人工经验设定，难以在不同工况下保持稳定的检测性能；最后，对于非突发性微小泄漏或间歇性泄漏，传统方法往往无能为力^[3]。这些局限性促使研究者逐渐转向数据驱动的检测方法。

1.2.2 基于机器学习的检测方法

随着机器学习技术的发展，研究者开始将特征工程与分类器相结合用于管道泄漏检测^[4]。此类方法的一般流程为：首先从原始传感器信号中提取时域特征（如均值、方差、峰值因子、峭度等）和频域特征（如频谱能量分布、小波包分解系数等），然后利用支持向量机、K 近邻、决策树等分类器进行泄漏状态判别^[5]。

这类方法相比于纯物理模型方法具有以下优势：一是可以自动学习数据中的判别模式，减少对人工阈值的依赖；二是能够在训练数据覆盖的工况范围内保持较好的检测效果。然而，传统机器学习方法仍然面临特征工程环节的设计瓶颈——人工提取的特征往往无法完整保留原始信号中的细粒度信息，且特征对不同泄漏形态、不同距离的区分度存在明显差异^[6]。此外，特征提取与分类器优化通常是分离进行的，无法实现端到端的联合优化。

1.2.3 基于深度学习的时序信号处理方法

近年来，深度学习在时序信号处理领域取得了显著进展。相比于传统方法，深度神经网络可以直接从原始信号中学习层次化的特征表示，避免了人工特征设计的主观性和不完整性^[7]。这种端到端的学习范式在大幅降低人工参与的同时，也使得模型能够发现人类专家可能忽略的细粒度信号模式。

在信号处理领域，一维卷积神经网络（1D-CNN）是最为常用的深度模型之一^[8]。1D-CNN 通过在时序维度滑动一维卷积核提取局部模式，并利用多层堆叠逐步扩大感受野，从而同时捕获局部波形特征与全局上下文信息。相比循环神经网络（RNN）及其变体 LSTM，1D-CNN 具有训练并行度高、参数量可控、梯度传播稳定等优势，更适合处理长度较长的时序信号^[6]。

在管道泄漏检测方面，Zhang 等人^[9]较早将 CNN 应用于管道声发射信号，验证了卷积网络在泄漏分类任务中的有效性。在此基础上，后续工作通过引入多尺度卷积^[2]、注意力机制^[2]等方式进一步提升检测精度。然而，现有工作大多将泄漏状态识别与位置估计作为单一任务处理，对分类目标与回归目标之间差异性的利用仍不充分。本文针对这一问题，采用“先分类、后定位”的两阶段处理框架，以降低单一模型的学习负担，并提升系统的可解释性与模块化程度。

1.2.4 深度学习在时序信号处理中的基础理论

本节简要回顾与本文方法密切相关的深度学习基础理论，为后续章节的模型设计提供理论支撑。

卷积神经网络的核心操作是卷积运算。对于一维输入信号 $\mathbf{x} \in \mathbb{R}^L$ 和卷积核 $\mathbf{w} \in \mathbb{R}^K$ ，卷积输出的第 t 个元素可表示为：

$$y_t = \sum_{k=0}^{K-1} w_k \cdot x_{t+k} \quad (1-1)$$

通过堆叠多个卷积层，网络能够逐层学习从低级到高级的特征表示。较低层主要响应信号中的局部波形模式（如突变、振荡），较高层则组合这些模式形成对特定泄漏形态的全局判别依据^[7]。

批归一化（Batch Normalization）是深度网络训练中的关键正则化技术^[10]。对于某一层的小批量输入 $\{z_1, z_2, \dots, z_m\}$ ，批归一化先计算批内均值 μ_B 与方差 σ_B^2 ，再进行如下变换：

$$\hat{z}_i = \frac{z_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad \tilde{z}_i = \gamma \hat{z}_i + \beta \quad (1-2)$$

该机制能够缓解训练过程中各层输入分布变化带来的不稳定性，使得梯度传播更加顺畅，从而允许使用更高的学习率和更少的正则化约束^[10]。

在激活函数方面，本文采用 GELU（Gaussian Error Linear Unit）^[11]。GELU 的数学形式为 $\text{GELU}(x) = x \cdot \Phi(x)$ ，其中 $\Phi(x)$ 为标准正态分布的累积分布函数。与 ReLU 的硬门控机制直接将负值置零不同，GELU 根据输入值以概率方式决定激活程度，在负值区域保留了部分信息。这种平滑的非线性变换有助于梯度在负值区域仍然有效传播，避免了 ReLU 中“神经元死亡”现象。实验表明其在多种视觉和信号处理任务中优于 ReLU^[11]。

1.3 研究问题与本文工作

结合现有数据条件与工程实现需求，本文关注的核心问题可以概括为：如何利用双通道长时序传感信号，在尽量减少人工特征设计的前提下，实现管道泄漏状态识别与泄漏距离估计。

围绕上述问题，本文完成了以下工作：

1. 设计了原始 CSV 信号到训练样本的自动化构建流程。针对原始双通道数据，按照固定时间窗口完成切分，并分别构建分类任务与回归任务所需的数据清单。

2. 构建了两阶段学习任务。其中，分类阶段（Stage2）用于识别信号所属类别，回归阶段（Stage1）用于对泄漏距离进行估计。
3. 设计了适用于长时序一维信号的卷积神经网络模型。模型采用多层一维卷积模块逐步降采样，并通过全局池化与任务头实现分类或回归输出。
4. 搭建了统一训练框架，并在分类任务中补充片段级与原始文件级评测指标，包括准确率、macro-F1 和混淆矩阵；在回归任务中除平均绝对误差与均方根误差外，进一步补充误差方向、容差命中率、按距离档位误差和文件级聚合误差分析，为实验结果解释提供更加完整的依据。

1.4 论文结构安排

本文按照研究问题、数据与方法、实验验证和总结展望的逻辑主线组织。全文共分为五章，各章内容安排如下：

1. 第一章为绪论，介绍研究背景、研究意义、研究问题与本文主要工作。
2. 第二章介绍管道泄漏探测的基本原理、泄漏声信号形成机制、信号数据特征以及数据集构建过程。
3. 第三章介绍本文所用深度学习方法基础、两阶段泄漏检测模型的整体结构、网络设计与训练策略。
4. 第四章介绍实验设计、评价指标与结果分析，重点讨论分类性能、距离估计误差、统计基线对比及影响因素。
5. 第五章总结全文工作，并对后续改进方向进行展望。

第二章 管道泄漏探测原理与数据集构建

2.1 管道泄漏探测基本原理

管道泄漏检测的核心目标是从传感器采集到的压力、振动或声学响应中识别异常状态，并进一步推断泄漏位置。管道处于正常运行状态时，内部流体流动与外部结构响应通常保持相对稳定；当管壁出现孔洞、裂纹或连接处密封失效时，流体会在压差作用下从破损位置喷出，局部流场发生突变，并激发与泄漏有关的瞬态波动和持续扰动。这些扰动沿管壁和流体介质传播，被布置在不同位置的传感器接收后形成可观测的时序信号。

从信号分析角度看，泄漏探测可以理解为从原始时序信号中提取能够区分正常状态、泄漏形态以及泄漏位置的特征。传统方法通常依赖时域统计量、频域能量分布或人工阈值规则；深度学习方法则直接从原始波形中学习特征表示。本文采用后一种思路，以固定长度的分段信号为输入，通过一维卷积网络自动提取局部波形模式和跨通道差异，从而完成泄漏识别与距离估计。

2.2 泄漏声信号形成机制

泄漏声信号的形成主要来源于泄漏点附近流体状态的突变。当管道内部介质经泄漏孔口向外喷射时，局部区域会产生湍流、压力脉动和结构振动。这些扰动一方面沿流体传播，另一方面也会耦合到管壁结构中形成振动响应，最终被布置在管道不同位置的传感器采集为时序波形信号。泄漏信号的频率成分和幅值大小受泄漏孔尺寸、管道压力、介质类型和环境背景噪声等多种因素共同影响，不同泄漏形态在时域波形和频域能量分布上可能表现出不同的特征模式。

对于布置在管道不同位置的左右两个传感通道而言，同一泄漏事件到达两个传感位置的传播路径、衰减程度和相位关系并不完全相同。泄漏点距离某一传感器越近，该通道的信号响应通常越早、幅值衰减越小；反之，波形能量衰减更明显，响应也可能更晚。因此，双通道信号之间的幅值差异、相位偏移和局部波形差异共同构成了泄漏距离估计的物理依据。

具体而言，若泄漏点靠近某一侧传感器，该侧通道可能表现出更明显的幅值变化、更早的响应或不同的局部频率成分；若泄漏点位于两侧传感器之间的不同位置，左右通道之间的相关性、能量差异和波形形态也会随之变化。本文没有手工构造到达时间差或频域峰值等特征，而是保留左右通道原始分段信号，由卷积

网络在训练过程中学习这些隐含差异。

2.3 数据特征分析与建模需求

本文实验数据具有以下特点。第一，单段信号长度较长。采样率为 25600 Hz、窗口长度为 5 s 时，每个通道包含 128000 个采样点，直接使用全连接网络建模会带来较高参数量和过拟合风险，因此需要采用具有参数共享机制的一维卷积网络进行降维处理。第二，信号具有典型时序连续性，相邻采样点之间并非独立取值，而是呈现连续波形起伏规律，这使得局部卷积适合提取短时波形模式。第三，回归任务使用左右双通道输入，通道间差异本身具有定位意义。同一泄漏事件在左右两个传感位置上的响应会随泄漏点相对位置变化而变化，因此模型需要同时利用单通道局部特征和双通道联合特征。第四，距离标签虽然以回归形式使用，但实际取值为若干离散档位。因此，实验分析不能只看总体平均误差，还应关注不同距离档位上的误差差异。

基于上述特征，本文在数据处理时采用固定窗口切分和逐段标准化，在模型设计时采用多层一维卷积逐步降采样，在结果分析时同时报告总体指标、按原始文件聚合后的指标以及按距离档位拆分的误差表现。

2.4 原始数据组织方式

本项目原始数据以 CSV 文件形式存储，并按照是否泄漏划分为 **raw/leak** 与 **raw/normal** 两类目录。每个文件对应一组实验采样记录，文件名采用 ABC 编号形式，例如 **ABC91.csv**。数据样本包含左右两个传感通道，分别对应后续建模中使用的左通道信号与右通道信号。数据处理脚本统一读取原始文件，跳过首行后将信号转为数值矩阵。

这种数据组织方式具有两个优点。其一，原始信号与实验编号一一对应，便于依据编号映射标签；其二，双通道结构保留了泄漏传播在不同传感位置上的响应差异，为距离估计提供了数据基础。此外，CSV 格式便于直接查看和调试，降低了数据处理流程的维护成本。

2.5 标签映射与任务拆分

数据准备脚本 `src/leak_detection/cli/prepare_dataset.py` 中定义了编号到标签的映射规则。对于发生泄漏的实验样本，每个编号区间同时对应两个标签信息：一是泄漏距离 **distance**，二是泄漏形态类别 **shape**；对于正常样本，

则只赋予正常类别标签，不参与距离回归任务。

基于这一映射关系，本文将原始问题拆分为两个子任务：

1. **Stage2** 为分类任务。输入为单通道分段信号，输出为三类标签，用于区分正常状态与两类不同泄漏形态。
2. **Stage1** 为回归任务。输入为同一时间窗口下的左右双通道信号对，输出为泄漏距离，用于估计泄漏位置。

这种两阶段设计的考虑在于：状态识别与距离估计虽然共享同一信号来源，但学习目标并不相同。状态识别关注整体波形形态差异，属于离散判别任务；距离估计关注双通道传播差异与泄漏距离之间的数值映射，属于回归任务。若直接使用单一模型同时完成两类目标，模型需要在同一特征空间中兼顾分类边界与回归精度，训练目标可能相互干扰。先完成状态判别，再针对泄漏样本进行距离估计，可以降低任务耦合度，使模型结构和实验分析更加清晰，也便于分别优化两个阶段的配置。

2.6 分段策略与样本生成

在数据处理过程中，原始长时序信号按照固定窗口进行切分。项目中默认采样率为 25600 Hz，分段时长为 5 s，因此单段样本长度为：

$$L = 25600 \times 5 = 128000 \quad (2-1)$$

对于每一个原始实验文件，脚本分别读取左通道与右通道数据，并按不重叠窗口进行切段。每个时间窗口都被保存为独立 CSV 文件，从而得到可直接供模型读取的分段样本。对于分类任务，左右通道被视为两条独立单通道样本；对于回归任务，左右通道在相同时间窗口下配对，形成双通道输入。

固定窗口非重叠切分方式具有实现简单、样本规模可扩展和便于批量训练等优点。对于长度为 5 秒的窗口，每个原始文件可生成多个分段样本，从而扩充训练数据规模；固定长度输入也便于卷积网络统一建模，无需引入可变长序列处理机制。不过，该策略没有显式建模不同窗口之间的时序关联，跨窗口上下文信息在当前方法中尚未被利用。此外，窗口长度本身是关键超参数：窗口过短可能导致单个样本信息不足，窗口过长则会减少样本数量并增加单样本计算开销。后续可进一步考虑重叠切窗、多分辨率切分或序列级建模方法。

2.7 数据集统计

根据当前仓库中已经生成的数据清单，本文所使用的数据规模如表2-1所示。

表 2-1 当前数据集统计结果

任务	样本数量	监督目标
Stage2 分类	3024	三分类标签
Stage1 回归	1122	泄漏距离

进一步统计各数据集分布发现, **Stage2** 任务的三类样本分布约为正常类 780 条、泄漏类别 1 为 1440 条、泄漏类别 2 为 804 条, 存在一定程度的类别不均衡; **Stage1** 任务的距离标签共有 9 个离散取值, 主要集中在 12、14 和 16 等位置附近。上述数据分布特征意味着: 分类任务需要关注类别偏置问题, 回归任务则需要重点分析不同距离区间上的预测误差。

2.8 相关损失函数与优化理论

本节从优化目标的角度介绍本文两阶段任务中使用的损失函数与优化方法, 为第三章模型训练策略提供理论依据。

2.8.1 交叉熵损失与分类任务优化

对于 **Stage2** 三分类任务, 本文采用交叉熵损失函数。交叉熵来源于信息论中的 Kullback-Leibler 散度, 用于衡量模型预测概率分布与真实标签分布之间的差异。设真实标签 y 对应的 one-hot 编码为 $\mathbf{y} \in \{0, 1\}^C$, 模型输出的类别概率为 $\hat{\mathbf{y}} \in [0, 1]^C$, 则交叉熵损失定义为:

$$\mathcal{L}_{ce} = - \sum_{c=1}^C y_c \log \hat{y}_c \quad (2-2)$$

交叉熵损失具有两个重要性质。第一, 当预测概率 $\hat{y}_c$ 完全匹配真实标签时损失为零, 偏离越大则损失越大, 梯度也会随之增大, 从而驱动模型更快速地校正错误预测。第二, **Softmax** 函数与交叉熵的组合在反向传播时具有简洁的梯度形式 $\nabla_{\mathbf{z}} \mathcal{L}_{ce} = \hat{\mathbf{y}} - \mathbf{y}$, 其中 $\mathbf{z}$ 为 **Softmax** 前的 logits 向量, 避免了梯度饱和问题。上述特性使得交叉熵成为分类任务中最常用的损失函数之一。

2.8.2 Smooth L1 损失与距离回归任务优化

对于 **Stage1** 距离回归任务, 本文采用 Smooth L1 损失^[7], 其分段定义为:

$$\mathcal{L}_{sl1}(d, \hat{d}) = \begin{cases} \frac{1}{2}(d - \hat{d})^2, & |d - \hat{d}| < 1 \\ |d - \hat{d}| - \frac{1}{2}, & |d - \hat{d}| \geq 1 \end{cases} \quad (2-3)$$

Smooth L1 的设计动机在于结合 L1 损失与 L2 损失的优点。当误差较小时 ($|d - \hat{d}| < 1$)，Smooth L1 退化为 L2 损失，提供光滑的梯度过渡，有利于精细调整；当误差较大时，Smooth L1 退化为 L1 损失，梯度绝对值恒为 1，避免了 L2 损失在大误差下梯度爆炸的风险。这一特性对于泄漏距离估计尤为重要——由于距离标签取值为多个离散档位，模型难免在部分样本上出现较大偏离，Smooth L1 可以有效控制此类离群样本对整体训练的影响，保障训练的稳定性。

2.8.3 AdamW 优化器与余弦退火调度

本文采用 AdamW 优化器^[12] 进行参数更新。AdamW 是在 Adam 基础上做出的改进，其核心区别在于将权重衰减（L2 正则化）与自适应学习率更新解耦。在标准 Adam 中，权重衰减项与梯度自适应项耦合，导致正则化效果受到学习率缩放的影响；AdamW 将权重衰减直接作用于参数更新步中，使得正则化强度独立于当前自适应学习率，从而获得更好的泛化性能。

在学习率调度方面，本文采用余弦退火策略。该策略使学习率沿着余弦曲线从初始值逐步衰减至接近零，数学形式为：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos\left(\frac{t}{T}\pi\right) \right) \quad (2-4)$$

其中 $\eta_{\max}$ 为初始学习率， $\eta_{\min}$ 为最终学习率， t 为当前训练轮数， T 为总训练轮数。余弦退火在训练初期保持较高学习率以快速收敛，后期以较小学习率进行精细调节，有助于模型收敛到更优的局部极小点。

第三章 两阶段泄漏检测模型设计

3.1 方法基础

本文模型属于监督学习框架。给定输入信号 x 与对应标签 y ，模型通过参数化函数 $f_{\theta}(x)$ 建立从信号到类别或距离的映射关系，并通过最小化损失函数更新参数 θ 。对于分类任务，标签为离散类别，训练目标是提高类别判别准确性；对于距离回归任务，标签为连续数值，训练目标是减小预测距离与真实距离之间的偏差。

一维卷积神经网络适用于处理时序信号。卷积核沿时间轴滑动，在局部窗口内共享参数，从而能够提取局部波形变化、短时冲击响应和局部振荡模式。与直接连接所有采样点的全连接网络相比，一维卷积具有参数共享和局部感受野的特点，能够在较少参数量下处理较长序列。随着网络层数增加，后续特征能够覆盖更大的时间范围，从而形成由局部到全局的多层次表示。

在本文任务中，批归一化用于缓解不同批量特征分布波动带来的训练不稳定问题，GELU 激活函数用于增强非线性表达能力，自适应平均池化用于将不同时间位置上的高维特征压缩为固定长度的全局表示。优化器采用 AdamW，其在 Adam 自适应学习率更新基础上引入解耦权重衰减，有助于提升训练稳定性并降低过拟合风险。

3.2 总体框架

本文采用的模型框架可概括为“数据切分、分类识别、距离估计”三个环节。首先，将原始双通道采样信号按照固定时间窗口切分为固定长度片段，并进行逐段标准化；其次，利用单通道分类模型（Stage2）对每个分段信号进行状态识别，判断其属于正常状态还是某一类泄漏形态；最后，对判定为泄漏的信号片段，利用双通道回归模型（Stage1）估计泄漏距离。分类与回归两个阶段采用独立模型参数，训练和推理时分别加载对应配置文件。

从代码实现角度看，任务入口统一由 `src/leak_detection/cli/train.py` 调用训练器，训练器根据配置文件自动选择任务类型、数据集类和网络结构。这种统一入口使分类任务与回归任务共享训练流程，并仅在数据组织、损失函数和评价指标上进行区分。后续若增加新的任务类型或网络变体，只需补充对应配置和数据集类，训练器核心逻辑无需大幅调整。

3.3 输入表示与归一化

模型输入由 `src/leak_detection/data/segmented.py` 完成读取。对于分类任务，每个样本为形状 1×128000 的单通道张量；对于回归任务，每个样本由左右通道堆叠形成形状 2×128000 的双通道张量。

考虑到不同实验样本的信号幅值范围可能存在差异，代码中对每个样本执行逐段标准化处理。设原始信号为 x ，均值为 μ ，标准差为 σ ，则归一化后的信号为：

$$\hat{x} = \frac{x - \mu}{\sigma + 10^{-6}} \quad (3-1)$$

当标准差接近零时，仅进行去均值操作，以避免除零问题。该策略有助于降低量纲差异对训练过程的影响，使网络更关注波形形态与通道间相对变化。

3.4 一维卷积特征提取网络

本文采用的一维卷积主干网络定义于 `src/leak_detection/models/signal_models.py`。网络由若干级卷积模块堆叠而成，每一级模块均包含以下操作：

1. 一层带步长的一维卷积，用于完成特征提取与时域降采样；
2. 批归一化层，用于稳定训练过程；
3. GELU 激活函数，用于增强非线性表达能力；
4. 第二层一维卷积与批归一化、GELU 组合，用于进一步提取局部模式。

模型配置中卷积通道数依次设置为 32、64、128 和 256，对应卷积核大小分别为 15、9、7 和 5，步长均为 4。通过四层降采样，每一层将时序长度缩减为原来的四分之一，原始 128000 点信号经过四层卷积后长度约为 $128000/4^4 = 500$ 。这种逐步压缩的设计使早期卷积层侧重捕获局部波形细节（如突变、振荡），后期卷积层则在更粗的时间尺度上组合局部信息，形成全局判别依据。经过多层卷积之后，模型采用自适应平均池化将所有位置的特征聚合为固定长度的全局特征向量，再通过全连接任务头映射到分类或回归输出空间。

这一结构实现简单、参数量可控，适合处理长度较长的一维信号。相比需要更大算力与更复杂位置编码机制的序列模型，一维卷积网络在当前数据规模和实验条件下更易训练，也更便于工程复现。

3.5 分类头与回归头设计

3.5.1 Stage2 分类模型

Stage2 分类任务使用单通道输入，模型主干输出全局特征后，经由两层全连接网络映射到三维类别空间，最终输出三类标签的预测结果。分类任务损失函数采用交叉熵损失，其表达式为：

$$\mathcal{L}_{cls} = - \sum_{c=1}^C y_c \log \hat{y}_c \quad (3-2)$$

其中， C 表示类别数量， y_c 为真实标签的 one-hot 编码， $\hat{y}_c$ 为模型输出的类别概率。

3.5.2 Stage1 回归模型

Stage1 回归任务使用双通道输入，模型输出单一实数作为泄漏距离预测值。与分类任务不同，回归任务不涉及 Softmax 归一化，全连接层直接输出连续数值。为增强对异常误差的鲁棒性，当前实现中优先采用 Smooth L1 损失：

$$\mathcal{L}_{reg}(d, \hat{d}) = \begin{cases} \frac{1}{2}(d - \hat{d})^2, & |d - \hat{d}| < 1 \\ |d - \hat{d}| - \frac{1}{2}, & |d - \hat{d}| \geq 1 \end{cases} \quad (3-3)$$

其中， d 为真实距离， $\hat{d}$ 为预测距离。相较于均方误差，Smooth L1 在误差较大时对离群点的敏感性更低，有利于提升回归训练的稳定性。

3.6 训练策略

统一训练流程定义于 `src/leak_detection/training/trainer.py`。训练器按照“加载配置、构建数据加载器、创建模型与优化器、迭代训练、验证评估、测试输出”的流程执行。当前实验采用 AdamW 优化器^[12]，初始学习率为 0.001，权重衰减为 0.0001，并使用余弦退火学习率调度器对学习率进行平滑衰减。训练最大轮数设置为 40，早停轮数设置为 8；当验证集指标连续 8 轮未提升时，训练提前终止，并保留验证集表现最优的模型参数。

此外，为避免梯度爆炸影响长时序训练稳定性，训练过程中对梯度范数进行裁剪，阈值为 1.0。分类任务以验证集准确率作为模型选择依据；回归任务以验证集 MAE 作为主要选择指标，并在测试阶段补充 RMSE、误差方向、容差命中率、最大误差、最小误差以及文件级聚合指标。训练完成后，程序自动加载最佳

验证模型，并在测试集上输出最终指标。

3.7 正则化与过拟合抑制策略

在参数量较大而训练样本相对有限时，深度学习模型容易出现过拟合，即训练集表现较好但测试集泛化能力下降。为缓解这一问题，本文从训练控制、参数约束和数据预处理三个层面设计正则化策略。

3.7.1 早停机制

早停是最简单有效的正则化手段之一。本文设定最大训练轮数为 40 轮，并采用验证集指标监测机制：若验证集指标连续 8 轮未出现改善，则提前终止训练，并恢复到验证集最优的模型参数。这一策略的出发点在于：随着训练进行，模型可能先学习到数据中的通用模式，而后逐渐记忆训练集中的噪声和异常样本。早停能够在模型开始过拟合之前及时停止，从而获得泛化能力更强的模型。

3.7.2 权重衰减

权重衰减 (Weight Decay) 等价于在损失函数中引入 L2 正则化项。设原损失函数为 $\mathcal{L}(\theta)$ ，则加入权重衰减后的总损失为：

$$\tilde{\mathcal{L}}(\theta) = \mathcal{L}(\theta) + \frac{\lambda}{2} \|\theta\|_2^2 \quad (3-4)$$

其中 λ 为权重衰减系数，本文取 0.0001。该项约束迫使模型参数趋于较小值，从而降低模型对输入信号的敏感程度，减小决策边界的复杂度。在 AdamW 优化器^[12] 中，权重衰减与自适应学习率解耦，使得正则化效果更加稳定。

3.7.3 梯度裁剪

在长时序信号建模中，单个样本包含 128000 个采样点，网络需要经过多层卷积逐步降采样，梯度在反向传播过程中可能累积放大，导致梯度爆炸。本文采用全局梯度范数裁剪策略，设定裁剪阈值为 1.0。设 $\mathbf{g}$ 为所有参数的梯度向量，若 $\|\mathbf{g}\|_2 > 1.0$ ，则按比例缩放：

$$\mathbf{g} \leftarrow \frac{1.0}{\|\mathbf{g}\|_2} \cdot \mathbf{g} \quad (3-5)$$

该操作确保梯度范数始终不超过 1.0，有效防止了极端梯度更新对模型参数造成破坏性影响。

3.7.4 批归一化的正则化效应

批归一化虽然最初是为解决内部协变量偏移而提出的^[10]，但其本身也具备一定的正则化效果。在训练过程中，批归一化使用当前小批量的均值和方差对特征进行标准化，由于每个批量的统计量存在随机波动，相当于在特征空间中引入了轻微的扰动噪声。这种隐式正则化在一定程度上可以替代 **Dropout** 的作用。因此，本文在卷积模块中采用批归一化而非 **Dropout**，既简化了模型结构，又保持了足够的正则化能力。

3.7.5 数据层面的泛化保障

除模型层面的正则化外，本文在数据处理阶段也采取了泛化保障措施。每个分段样本在输入网络之前会进行逐段标准化处理，减去自身均值并除以标准差。该操作消去了不同样本之间的幅值差异，使网络更关注波形相对形态而非绝对幅值，从而增强了对不同实验条件下信号幅值变化的适应能力。此外，随机种子固定为 42，保证训练集、验证集与测试集划分在不同实验中保持一致，消除了数据划分随机性带来的结果波动。

第四章 实验设计与结果分析

4.1 实验环境与配置

本文实验基于 Python 与 PyTorch 深度学习框架完成，数据集构建与模型训练均通过命令行工具调用，实验流程具有较好的可复现性。当前项目提供两个主要配置文件：`configs/stage2.yaml` 用于分类实验，`configs/stage1.yaml` 用于回归实验。两者在主干网络结构上保持一致，主要区别体现在输入形式、任务头、损失函数与评价指标上。

为保证不同实验之间具有可比性，本文固定随机种子为 42，并保持训练集、验证集和测试集划分一致。若后续开展超参数对比实验，可围绕卷积通道数、卷积核大小、损失函数和窗口长度等因素展开。

4.2 评价指标

4.2.1 分类任务指标

对于 Stage2 分类任务，本文采用准确率、macro-F1 和混淆矩阵作为主要评价指标。仅依赖准确率可能掩盖模型在少数类上的识别不足，因此引入 macro-F1 以更均衡地反映各类别性能。混淆矩阵用于展示不同类别之间的误分类模式，便于分析模型在哪些类别对之间容易发生混淆。准确率定义为：

$$Accuracy = \frac{N_{correct}}{N_{total}} \quad (4-1)$$

其中， $N_{correct}$ 表示预测正确的样本数量， N_{total} 表示测试样本总量。macro-F1 先分别计算每个类别的精确率（Precision）和召回率（Recall），由二者调和平均得到该类别的 F1 值，再对各类别结果进行等权平均。由于 macro-F1 不对多数类赋予更高权重，因此更适合用于观察类别不均衡条件下的分类效果。此外，本文同时统计片段级混淆矩阵与原始文件级混淆矩阵，用于分析不同评测层级下的误分类关系。

4.2.2 回归任务指标

对于 Stage1 回归任务，本文采用平均绝对误差与均方根误差作为主要指标，分别表示为：

$$MAE = \frac{1}{N} \sum_{i=1}^N |d_i - \hat{d}_i| \quad (4-2)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (d_i - \hat{d}_i)^2} \quad (4-3)$$

其中， d_i 为真实距离， $\hat{d}_i$ 为预测距离。MAE 反映平均偏差水平，RMSE 对较大误差更加敏感，二者结合能够较全面地反映定位性能。

为增强回归结果的物理可解释性，本文进一步统计有符号误差 $e_i = \hat{d}_i - d_i$ 、最大绝对误差、最小绝对误差以及容差命中率。容差命中率定义为：

$$Acc_{\tau} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(|\hat{d}_i - d_i| \leq \tau) \quad (4-4)$$

其中， τ 表示允许误差阈值。本文重点报告 $\tau = 1.0$ 时的结果，用于衡量预测值是否落在真实距离附近一个单位范围内。由于同一原始文件会被切分为多个片段，本文还对同一原始文件下的片段预测结果求平均，得到文件级距离预测，并计算对应的文件级 MAE、RMSE 和最大误差。

4.3 实验结果

基于当前仓库中的正式训练结果，本文分别对 **Stage2** 分类任务与 **Stage1** 回归任务进行分析。所有实验均采用相同随机种子与文件级划分方式，以保证训练集、验证集与测试集之间具有可比性，并尽量降低数据划分随机性对结果解释的影响。

4.3.1 Stage2 分类结果

Stage2 任务以单通道分段信号为输入，输出正常状态与两类泄漏形态的三分类结果。实验结果如表4-1 所示。模型在测试集上取得了较高的片段级分类性能，片段级准确率达到 0.9968，片段级 **macro-F1** 达到 0.9972。进一步将同一原始文件下的所有片段预测进行聚合后，文件级准确率与文件级 **macro-F1** 均达到 1.0000，说明模型在当前随机文件级划分下，对测试文件具有较强识别能力。

从混淆矩阵看，片段级测试样本中仅存在一次误分类，即真实类别 1 的一个片段被误判为类别 2，其余样本均被正确识别。文件级混淆矩阵全部位于主对角线上，表明测试集中 26 个原始文件均被正确分类。上述结果说明，模型性能并非仅由多数类样本支撑，而是在当前测试集的各类别上均表现稳定。

唯一误分类片段发生在类别 1 与类别 2 之间，而正常样本（类别 0）均被正

表 4-1 Stage2 分类任务测试结果

评测层级	指标	数值
片段级	Accuracy	0.9968
片段级	Macro-F1	0.9972
文件级	Accuracy	1.0000
文件级	Macro-F1	1.0000

确区分。这一现象具有一定合理性：正常信号与泄漏信号在波形形态上差异较明显，模型较容易学习二者边界；而两类泄漏形态之间可能存在更强的波形相似性，因此少数边界样本仍可能发生混淆。从文件级角度看，将同一原始文件下的多个片段按平均 **logits** 聚合后，所有测试文件均被正确分类，说明文件级聚合能够有效削弱个别片段预测波动。

4.3.2 Stage1 距离回归结果

Stage1 任务以同一时间窗口下的左右双通道信号对为输入，输出泄漏距离预测值。实验结果如表4-2 所示。模型在验证集上的最佳平均绝对误差为 **0.3148**；在测试集上，平均绝对误差为 **0.3703**，均方根误差为 **0.5934**。测试误差相较验证集略有上升，但差距较小，说明模型在当前划分下具有较好的距离估计稳定性。

表 4-2 Stage1 回归任务结果

数据划分	指标	数值
验证集最优模型	MAE	0.3148
测试集	MAE	0.3703
测试集	RMSE	0.5934

为检验模型是否真正利用了输入信号，本文进一步设置两种不使用信号的统计基线：一是始终预测训练集距离均值，二是始终预测训练集距离中位数。对比结果如表4-3 所示。统计基线的测试集 **MAE** 分别为 **4.4040** 和 **3.8571**，显著高于本文模型的 **0.3703**。这说明模型并非仅学习距离标签的整体分布，而是捕获了双通道信号模式与泄漏距离之间的有效映射关系。

进一步从物理误差角度分析，本文统计了最小绝对误差、最大绝对误差、误差方向和预测距离范围，结果如表4-4 所示。片段级最小绝对误差为 **0.0060**，最大绝对误差为 **2.4668**；有符号误差最小值为 **-2.4668**，最大值为 **1.1769**，说明较

表 4-3 Stage1 回归任务统计基线对比

方法	预测策略	MAE	RMSE
训练集均值基线	恒定预测 9.3594	4.4040	4.7855
训练集中位数基线	恒定预测 11.0000	3.8571	4.9425
本文一维卷积模型	双通道信号回归	0.3703	0.5934

大误差主要表现为低估。片段级误差不超过 1 个距离单位的比例为 0.9286。将同一原始文件下多个片段的预测取均值后，文件级 MAE 降至 0.2534，RMSE 降至 0.4603，表明多片段聚合能够进一步削弱单段预测波动。

表 4-4 Stage1 回归任务物理误差分析

指标	片段级	文件级
MAE	0.3703	0.2534
RMSE	0.5934	0.4603
最小绝对误差	0.0060	0.0029
最大绝对误差	2.4668	1.8852
平均有符号误差	-0.1504	-0.1504
最大低估误差	-2.4668	-1.8852
最大高估误差	1.1769	0.3124
误差 ≤ 1.0 占比	0.9286	0.9524
预测距离范围	1.9274–16.1776	2.0277–15.7598

由于距离标签为多个离散档位，本文进一步按真实距离拆分误差，结果如表4-5 所示。可以看出，大多数距离档位的 MAE 均低于 0.5，且误差不超过 1 个距离单位的比例接近或达到 1.0；但距离 16 的 MAE 为 1.1186，平均有符号误差为 -1.0627，明显存在低估现象。该现象说明模型在高距离档位上的定位能力相对较弱，可能与该距离档位样本数量、信号衰减特征或与相邻距离档位的波形相似性有关。

从最大误差样本看，片段级最大绝对误差来自 ABC155，真实距离为 12，预测值为 9.5332，误差为 -2.4668；文件级最大误差来自 ABC162，真实距离为 16，多个片段平均预测为 14.1148，误差为 -1.8852。从误差方向上看，平均有符号误差为 -0.1504，说明模型整体呈现出轻微低估的倾向，即预测距离略小于真实距离。这一偏差在高距离档位（距离 16）上尤为突出，平均有符号误差达到 -1.0627，

表 4-5 Stage1 按距离档位的片段级误差

真实距离	样本数	MAE	最大绝对误差	平均有符号误差
2	6	0.0750	0.1482	0.0277
3	24	0.2519	0.8743	0.0756
4	6	0.2327	0.3438	-0.0435
5	6	0.1849	0.4042	-0.1465
11	18	0.4296	1.3331	0.0747
12	30	0.3519	2.4668	-0.1672
14	24	0.2476	0.6062	-0.1403
16	12	1.1186	2.2493	-1.0627

说明模型在该距离上存在系统性低估现象。可能的原因包括：该距离档位的训练样本数量较少（仅 144 个样本中的 12 个出现在测试集中），导致模型对该距离的估计能力不足；此外，远距离泄漏信号在传播过程中衰减加剧，信号特征减弱，使得模型倾向于将模糊输入预测为更常见的中间距离值。这进一步说明后续优化应重点关注高距离档位及个别异常文件的误差来源。

表 4-6 两阶段任务主要实验结果汇总

任务	测试指标 1	测试指标 2	备注
Stage2 分类	Accuracy = 0.9968	Macro-F1 = 0.9972	文件级 Accuracy = 1.0000
Stage1 回归	MAE = 0.3703	RMSE = 0.5934	双通道距离估计

4.4 结果分析

综合分类与回归实验结果可以看出，本文提出的两阶段框架在当前数据集与划分设置下取得了较好的性能。对于 Stage2 分类任务，模型能够有效区分正常状态与两类泄漏形态，说明一维卷积特征提取方式能够捕获分段信号中的判别性波形差异。引入原始文件级聚合评测后，模型仍获得 1.0000 的文件级准确率与文件级 macro-F1，表明片段级偶发误差不会直接导致文件级决策错误。

对于 Stage1 回归任务，测试集 MAE 为 0.3703，RMSE 为 0.5934，明显优于简单均值预测或中位数预测等统计基线，表明双通道输入为泄漏距离估计提供了有效信息。由于当前距离标签为多个离散取值，该误差水平说明模型通常能

够将预测结果控制在相邻距离档位附近。从按距离档位拆分的误差结果看，近距离档位（2–6）的 MAE 普遍较低（0.0750–0.2519），远距离档位 16 的 MAE 明显偏高（1.1186）。这种距离相关的不对称性可能与信号传播衰减有关：泄漏信号在远距离传播后衰减加剧，信噪比降低，模型从波形中提取稳定定位信息的难度随之增加。

从模型性能分析角度看，当前实验提供了三个层面的证据。第一，与不使用信号输入的统计基线相比，一维卷积模型显著降低 MAE 和 RMSE，验证了信号特征对于距离估计的必要性。第二，片段级与文件级结果对比表明，同一原始文件的多片段预测均值能够进一步降低误差，说明实际应用中可优先采用文件级或时间段级聚合结果作为最终定位输出。第三，按距离档位拆分后的误差表明，总体平均指标不能完全反映模型行为，高距离档位 16 的低估问题是当前回归任务的主要误差来源。

消融实验方面，本文当前代码已保留若干可配置项，例如回归损失可在 Smooth L1 与 MSE 之间切换，网络通道数、卷积核大小、窗口长度和归一化策略也可以作为后续变量。受当前实验周期限制，本文未将所有消融结果作为正式表格展开，而是将已完成的统计基线和聚合层级对比作为现阶段模型有效性验证。后续若进一步完善实验，可围绕“是否使用双通道输入”“Smooth L1 与 MSE 损失对比”“不同窗口长度对定位精度的影响”“是否进行文件级聚合”四个方向开展系统消融，以更细致地量化各模块贡献。

需要指出的是，本文结果建立在当前随机文件级划分基础上。具体而言，数据划分以原始文件为单位进行，同一文件的所有分段样本均被分配到同一数据子集中，避免了相似片段同时出现在训练集和测试集中导致指标虚高。然而，测试集仅包含 26 个原始文件，规模仍然有限，且不同文件之间可能具有相似实验条件与工况配置。因此，当前结果应理解为现有数据条件下的有效验证，而非模型泛化能力的最终结论。后续可在保持现有评测指标的基础上，设计更加严格的数据切分策略，如按批次分组划分、按工况条件分层划分，并补充跨工况或跨批次泛化实验。

从消融实验的扩展设计角度看，本文代码框架已保留多组可配置参数供后续系统验证。例如，可通过调整输入窗口长度，对比 2 s、5 s 和 10 s 信号片段对分类准确率和回归 MAE 的影响；也可通过切换回归损失函数类型（Smooth L1、MSE 或 MAE），分析不同损失函数对距离估计偏差和离群点敏感性的影响；还可以通过减少卷积层数或调整通道数，研究网络容量与模型性能之间的关系。此外，通过对比单通道输入与双通道输入在回归任务上的表现，可以量化双通道信息在泄漏距离估计中的实际贡献。这些消融实验虽未在当前报告中全部展开，但本文搭建的训练框架和支持代码为相关实验的快速执行提供了基础。

总体而言，当前实验结果验证了两阶段方案的有效性：分类任务能够可靠地区分正常状态与泄漏形态，回归任务能够在较小误差范围内估计泄漏距离。按距离档位拆分的误差分析进一步揭示了模型在不同场景下的行为差异，为有针对性的模型优化提供了方向。这为后续继续开展模型改进、切分优化和部署适配奠定了较为扎实的实验基础。

第五章 结论与展望

5.1 全文总结

本文围绕双通道管道传感信号的泄漏检测与定位问题，完成了从数据构建、任务拆解到模型设计与实验验证的研究流程。主要工作可概括为以下几个方面：

第一，构建了从原始 CSV 信号到训练样本的自动化处理流程。针对 25600 Hz 采样率的双通道长时序数据，按照 5 秒固定窗口进行非重叠切分，并分别为分类任务（Stage2）和回归任务（Stage1）建立了结构化的数据清单。分类数据集包含 3024 条单通道样本，回归数据集包含 1122 对双通道样本。在数据预处理阶段引入逐段标准化操作，消除了不同样本之间的幅值差异，增强了模型对信号幅值波动的鲁棒性。

第二，设计了两阶段泄漏检测框架，将复杂的泄漏检测与定位问题拆分为“先分类、后定位”的子任务序列。Stage2 分类任务以单通道分段信号为输入，采用一维卷积神经网络实现三分类识别，用于区分正常状态与两类泄漏形态；Stage1 回归任务以左右双通道信号对为输入，采用结构相同的卷积网络实现泄漏距离估计。两阶段设计降低了单一模型的学习负担，使状态识别与位置估计的任务目标更加清晰，同时增强了整体框架的可解释性和模块化程度。

第三，搭建了统一的训练框架与多维度评测体系。训练框架通过配置文件区分任务类型、数据集和网络结构，支持分类与回归任务的统一调度与灵活扩展。在评价指标方面，分类任务同时采用片段级与原始文件级准确率、macro-F1 和混淆矩阵；回归任务除平均绝对误差与均方根误差外，进一步补充了最小最大误差、误差方向、容差命中率、按距离档位拆分误差和文件级聚合误差等分析指标，为全面理解模型行为提供了数据支撑。

第四，完成了统计基线对比与多角度误差分析。将本文模型与均值预测、中位数预测等简单统计基线进行了定量对比，验证了模型确实从信号中学习了有意义的特征映射。按距离档位拆分的误差分析揭示了高距离档位（距离 16）的系统性低估问题，为后续模型改进指明了方向。

从工程实现角度看，本文已形成较为完整的实验流水线，包括原始数据自动切分、数据加载、模型训练、验证集选择与测试集评估等模块。该流程基于配置文件驱动，不同任务只需切换配置文件即可运行，结构清晰、复现方便，为后续开展对比实验与性能优化提供了基础。

在实验结果方面，本文方法在当前随机文件级划分下取得了如下结果：Stage2

分类任务测试集片段级准确率达到 0.9968，片段级 macro-F1 达到 0.9972，文件级准确率与 macro-F1 均达到 1.0000；Stage1 回归任务测试集平均绝对误差为 0.3703，均方根误差为 0.5934，文件级聚合后 MAE 降至 0.2534，RMSE 降至 0.4603，误差不超过 1 个距离单位的比例为 0.9286。上述结果验证了两阶段框架在当前数据条件下的有效性。

5.2 后续工作展望

尽管本文已经完成两阶段泄漏检测方法的基本实现与实验验证，但仍有若干方向值得进一步研究：

1. 在数据层面，当前数据规模相对有限，且测试集仅覆盖了部分距离档位和泄漏形态。后续可进一步扩充不同工况（如压力、流量变化）、不同噪声条件（如环境噪声、传感器噪声）和更多距离位置的实验样本，以提升模型的泛化能力和在实际复杂场景中的适用性。
2. 在模型层面，当前一维卷积网络结构较为简洁，后续可尝试引入多尺度卷积以捕获不同时间分辨率下的泄漏特征，采用残差连接以缓解网络加深带来的梯度衰减问题，或结合注意力机制使模型更加关注信号中的关键时序区域。此外，时频联合建模（如将短时傅里叶变换或小波变换与卷积网络结合）也是一个值得探索的方向。
3. 在任务层面，当前分类与回归任务使用独立的模型和训练流程。后续可考虑将两阶段设计为端到端的联合学习框架，探索共享底层特征表示是否能够进一步提升整体性能。同时，对分类阶段已识别的泄漏样本，还可引入更精细的泄漏形态子分类，为后续维护决策提供更多信息。
4. 在应用层面，当前模型参数量和推理速度能够满足离线实验分析需求，但距离实时在线检测仍有差距。后续可围绕模型轻量化（如知识蒸馏、网络剪枝、量化部署）和边缘端推理展开研究。此外，还可探索在线增量学习机制，使模型在部署后持续适应新的工况变化，减少对离线重新训练的依赖。

总体而言，本文围绕“数据构建—任务拆解—模型设计—实验验证”四个环节，完成了一套面向双通道传感信号的两阶段管道泄漏检测与定位方案。在当前数据集与实验条件下，该方案在分类任务上取得了较高识别性能，在回归任务上取得了明显优于统计基线的距离估计精度，验证了基于分段时序信号与深度学习方法开展管道泄漏检测与定位的技术可行性，也为后续更广泛工况验证、模型优化和工程部署奠定了基础。

参考文献

- [1] Li J, Zheng Q, Li Z, et al. Pipeline leak detection: A comprehensive review of methods and technologies [J]. *Measurement*, 2023, 198: 111–125.
- [2] Sharma A, Kumar V, Gupta R. Pipeline leak localization using acoustic emission and machine learning: A review [J]. *Process Safety and Environmental Protection*, 2022, 158: 531–548.
- [3] Kıymık M K, Güler I, Dizibüyük A, et al. Comparison of STFT and wavelet transform methods in determining epileptic seizure activity in EEG signals for real-time application [J]. *Computers in biology and medicine*, 2005, 35 (7): 603–616.
- [4] Chen X, Wang J, Liu Y. SVM-based pipeline leak detection with feature extraction from acoustic signals [J]. *IEEE Sensors Journal*, 2020, 20 (16): 9450–9461.
- [5] 周志华. 机器学习 [M]. 北京: 清华大学出版社, 2016: 181–185.
- [6] Wang Z, Oates T, et al. Deep learning for time series signal analysis: A survey [J]. *Information Fusion*, 2022, 77: 145–167.
- [7] Goodfellow I, Bengio Y, Courville A. Deep learning [M]. MIT Press, 2016.
- [8] Kiranyaz S, Avci O, Abdeljaber O, et al. 1D convolutional neural networks and applications: A survey [J]. *Mechanical Systems and Signal Processing*, 2021, 151: 107–128.
- [9] Zhang Y, Chen S, Li W. A CNN-based pipeline leak detection method using acoustic signals [C]. In *IEEE International Conference on Acoustics, Speech and Signal Processing*, 2019: 2765–2769.
- [10] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift [C]. In *International Conference on Machine Learning*, 2015: 448–456.
- [11] Hendrycks D, Gimpel K. Gaussian error linear units (GELUs) [J]. *arXiv preprint arXiv:1606.08415*, 2016.
- [12] Loshchilov I, Hutter F. Decoupled weight decay regularization [C]. In *International Conference on Learning Representations*, 2019.
- [13] 李晟洁, 李翔, 张越, 等. 基于 Wi-Fi 信道状态信息的行走识别与行走参数估计 [J]. *软件学报*, 2021, 32 (10): 3122–3138.
- [14] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets [J]. *Advances in Neural Information Processing Systems*, 2014, 27.

致 谢

本论文的完成得益于多位老师和同学的帮助与支持，在此谨向他们表示诚挚的感谢。

首先，衷心感谢我的指导老师。在毕业设计期间，老师在选题方向、技术路线和研究方法上给予了充分的指导和支持，耐心解答了我在研究过程中遇到的各种问题，并在论文撰写阶段提出了许多宝贵的修改意见。老师严谨的治学态度和扎实的专业素养让我受益匪浅。

其次，感谢实验室的各位同学。他们在日常科研讨论中分享了许多有价值的思路和方法，在实验实施和数据分析过程中也提供了不少帮助。与他们的交流和协作使我的研究工作更加顺利。

感谢天津大学智能与计算学部四年来的培养。学部提供的良好学习环境和科研平台为本文研究的顺利开展提供了基础保障。

最后，感谢我的家人和朋友在学业期间给予的理解、鼓励和支持。他们的关心是我能够顺利完成学业的重要动力。