

天津大学

本科生毕业论文



题目：语义社团导向的社交网络深度表征学习

学 院	智算学部
专 业	计算机科学与技术
年 级	2020 级
姓 名	膜法师
学 号	3020216666
指导教师	膜导师

摘 要

针对管道输送系统中泄漏故障发现困难、人工特征设计依赖较强以及定位精度不足的问题,本文围绕双通道时序传感信号,研究了一种基于深度学习的两阶段管道泄漏检测与定位方法。首先,依据原始 CSV 采样数据构建自动化数据处理流程,将长时序双通道信号按照固定时间窗口切分为可训练样本,并分别生成用于分类任务与回归任务的数据清单。其次,针对泄漏状态识别与泄漏距离估计两个目标,设计了统一的一维卷积神经网络框架。其中,第二阶段分类任务以单通道分段信号为输入,用于识别正常状态与两类不同泄漏形态;第一阶段回归任务以左右双通道信号对为输入,用于估计泄漏距离。最后,基于统一训练框架完成模型训练、验证与测试,并从片段级与原始文件级两个层面分析分类性能,同时采用平均绝对误差和均方根误差评价距离估计效果。实验结果表明,在当前随机文件级划分下,本文方法在分类任务上取得了较高识别性能,测试集片段级准确率达到 0.9968,片段级 macro-F1 达到 0.9972,按原始文件聚合后的文件级准确率与文件级 macro-F1 均达到 1.0000;在距离回归任务上,测试集平均绝对误差为 0.3703,均方根误差为 0.5934。结果说明,本文提出的两阶段方法能够有效完成管道泄漏状态识别与距离估计任务,并为后续进一步开展严格泛化验证与工程部署提供了实验基础。

关键词: 管道泄漏检测, 时序信号分析, 深度学习, 一维卷积神经网络, 距离回归

ABSTRACT

To address the difficulty of leak discovery, the strong dependence on handcrafted features, and the insufficient localization accuracy in pipeline transport systems, this thesis studies a two-stage pipeline leak detection and localization method based on dual-channel time-series sensor signals. First, an automated data processing pipeline is constructed from raw CSV measurements. Long dual-channel signals are segmented with a fixed time window to generate trainable samples for both classification and regression tasks. Second, a unified one-dimensional convolutional neural network framework is designed for leak recognition and distance estimation. In the classification stage, segmented single-channel signals are used to identify normal states and two different leak patterns. In the regression stage, paired left-right channel signals are used to estimate leak distance. Finally, a unified training framework is employed for model optimization, validation, and testing. Classification performance is evaluated at both the segment level and the original-file level, while distance estimation performance is measured by mean absolute error and root mean square error. Experimental results show that, under the current random file-level split, the proposed method achieves strong performance on the classification task, with a segment-level accuracy of 0.9968, a segment-level macro-F1 of 0.9972, and both file-level accuracy and file-level macro-F1 reaching 1.0000 on the test set. On the distance regression task, the test mean absolute error is 0.3703 and the root mean square error is 0.5934. These results indicate that the proposed two-stage method can effectively accomplish both leak state recognition and distance estimation, and provide an experimental basis for subsequent stricter generalization evaluation and engineering deployment.

KEY WORDS: Pipeline Leak Detection, Time-series Signal Analysis, Deep Learning, One-dimensional Convolutional Neural Network, Distance Regression

目 录

第一章	绪论	1
1.1	研究背景与意义	1
1.2	研究问题与本文工作	1
1.3	论文结构安排	2
第二章	数据集构建与任务定义	3
2.1	原始数据组织方式	3
2.2	标签映射与任务拆分	3
2.3	分段策略与样本生成	3
2.4	数据集统计	4
第三章	两阶段泄漏检测模型设计	5
3.1	总体框架	5
3.2	输入表示与归一化	5
3.3	一维卷积特征提取网络	5
3.4	分类头与回归头设计	6
3.4.1	Stage2 分类模型	6
3.4.2	Stage1 回归模型	6
3.5	训练策略	6
第四章	实验设计与结果分析	8
4.1	实验环境与配置	8
4.2	评价指标	8
4.2.1	分类任务指标	8
4.2.2	回归任务指标	8

4.3	实验结果	9
4.3.1	Stage2 分类结果	9
4.3.2	Stage1 距离回归结果	10
4.4	结果分析	10
第五章	结论与展望	12
5.1	全文总结	12
5.2	后续工作展望	12
参考文献		13
致 谢		14

第一章 绪论

1.1 研究背景与意义

管道输送系统广泛应用于能源、化工与市政基础设施等场景，其运行安全直接关系到生产连续性、环境安全与维护成本。实际运行过程中，泄漏故障具有隐蔽性强、传播范围广、发现滞后等特点，一旦未被及时发现，容易造成介质损失、设备损坏甚至安全事故。因此，构建能够面向原始传感信号进行自动识别与定位的泄漏检测方法，具有较强的工程应用价值。

传统泄漏检测方法通常依赖人工经验、阈值规则或频域特征分析。此类方法在结构简单、噪声可控的场景下具有一定效果，但面对复杂工况、长时序原始信号以及不同泄漏形态时，往往存在特征设计依赖人工、泛化能力有限、定位精度不足等问题。随着深度学习在时序建模中的应用逐渐成熟，直接从原始信号中学习判别特征，为管道泄漏检测与定位提供了新的技术路径。

基于此，本文围绕双通道管道传感信号，设计了一种两阶段泄漏检测框架。该框架首先对分段时序信号进行泄漏形态分类，再对泄漏样本进行距离估计，从而将复杂定位问题拆分为“状态识别”与“位置估计”两个相对清晰的子任务，以提升模型训练稳定性与整体任务可解释性。

1.2 研究问题与本文工作

结合现有数据与代码实现，本文关注的核心问题可以概括为：如何利用双通道长时序传感信号，在较少人工特征设计的前提下，实现管道泄漏状态识别与泄漏距离估计。

围绕上述问题，本文完成了以下工作：

1. 设计了原始 CSV 信号到训练样本的自动化构建流程。针对原始双通道数据，按照固定时间窗口完成切分，并分别构建分类任务与回归任务所需的数据清单。
2. 构建了两阶段学习任务。其中，第二阶段任务用于识别信号所属类别，第一阶段任务用于对泄漏距离进行回归估计。
3. 设计了适用于长时序一维信号的卷积神经网络模型。模型采用多层一维卷积模块逐步降采样，并通过全局池化与任务头实现分类或回归输出。
4. 搭建了统一训练框架，并在分类任务中补充片段级与原始文件级评测指

标，包括准确率、macro-F1 和混淆矩阵；在回归任务中输出平均绝对误差与均方根误差，为实验分析提供更加完整的依据。

1.3 论文结构安排

全文共分为五章，各章内容安排如下：

1. 第一章为绪论，介绍研究背景、研究意义、研究问题与本文主要工作。
2. 第二章介绍数据集构建过程与任务定义，说明原始数据组织方式、标签映射关系和分段策略。
3. 第三章介绍两阶段泄漏检测模型的整体结构、网络设计与训练方法。
4. 第四章介绍实验设计、评价指标与结果分析，重点讨论分类性能、距离估计误差及影响因素。
5. 第五章总结全文工作，并对后续改进方向进行展望。

第二章 数据集构建与任务定义

2.1 原始数据组织方式

本项目原始数据以 CSV 文件形式存储，按照是否泄漏划分为两个目录，即 **raw/leak** 与 **raw/normal**。每个文件对应一组实验采样记录，文件名采用 **ABC** 编号形式，例如 **ABC91.csv**。从代码实现上看，原始文件被统一读入，并在跳过首行后转为数值矩阵。数据样本中包含左右两个传感通道，分别对应后续建模中使用的左通道信号与右通道信号。

这种数据组织方式有两个优点。其一，原始信号与实验编号一一对应，便于后续依据编号映射标签；其二，双通道结构保留了泄漏传播在不同传感位置上的响应差异，为后续距离估计提供了基础。

2.2 标签映射与任务拆分

数据准备脚本 `src/leak_detection/cli/prepare_dataset.py` 中定义了编号到标签的映射规则。对于发生泄漏的实验样本，每个编号区间同时对应两个标签信息：一是泄漏距离 **distance**，二是泄漏形态类别 **shape**；对于正常样本，则只赋予正常类别标签，不参与距离回归任务。

基于这一映射关系，本文将原始问题拆分为两个子任务：

1. **Stage2** 为分类任务。输入为单通道分段信号，输出为三类标签，用于区分正常状态与两类不同泄漏形态。
2. **Stage1** 为回归任务。输入为同一时间窗口下的左右双通道信号对，输出为泄漏距离，用于估计泄漏位置。

这种两阶段设计的考虑在于：如果直接从原始信号同时完成状态识别与位置估计，模型需要同时学习类别边界与位置回归关系，训练难度较大。先完成状态判别，再针对泄漏样本估计距离，可以在一定程度上降低任务耦合度，使模型结构与实验分析更加清晰。

2.3 分段策略与样本生成

在数据处理过程中，原始长时序信号按照固定窗口进行切分。项目中默认采样率为 25600 Hz，分段时长为 5 s，因此单段样本长度为：

$$L = 25600 \times 5 = 128000 \quad (2-1)$$

对于每个原始文件，脚本分别读取左通道与右通道数据，并按不重叠窗口进行切段。每个时间窗口都被保存为独立 CSV 文件，从而得到可直接供模型读取的分段样本。对于分类任务，左右通道被视为两条独立单通道样本；对于回归任务，左右通道在相同时间窗口下配对，形成双通道输入。

这种固定窗口切分方式具有实现简单、样本规模可扩展、便于批量训练等优点。同时，固定长度输入也便于卷积网络进行统一建模。不过，该策略也存在局限，即不同窗口之间没有显式时序关联，若要进一步利用跨窗口上下文信息，后续可以考虑引入重叠切窗或序列级建模方法。

2.4 数据集统计

根据当前仓库中已经生成的数据清单，本文所使用的数据规模如表2-1所示。

表 2-1 当前数据集统计结果

任务	样本数量	监督目标
Stage2 分类	3024	三分类标签
Stage1 回归	1122	泄漏距离

进一步统计发现，Stage2 任务的三类样本分布约为正常类 780 条、泄漏类别 1 为 1440 条、泄漏类别 2 为 804 条，存在一定程度的类别不均衡；Stage1 任务的距离标签共有 9 个离散取值，主要集中在 12、14 和 16 等位置附近。上述数据分布特征意味着：分类任务需要关注类别偏置问题，回归任务则需要重点分析不同距离区间上的预测误差。

第三章 两阶段泄漏检测模型设计

3.1 总体框架

本文采用的模型框架如图示流程所示，可概括为“数据切分、分类识别、距离估计”三个环节。首先，将原始双通道采样信号切分为固定长度片段；其次，利用单通道分类模型对分段信号进行状态识别；最后，对已知为泄漏的信号片段，利用双通道回归模型估计泄漏距离。

从代码实现角度看，任务入口统一由 `src/leak_detection/cli/train.py` 调用训练器，训练器根据配置文件自动选择任务类型、数据集类和网络结构。这样的设计使分类任务与回归任务共享训练流程，只在数据组织、损失函数和评价指标上进行区分，有利于后续对比实验与复现实验。

3.2 输入表示与归一化

模型输入由 `src/leak_detection/data/segmented.py` 完成读取。对于分类任务，每个样本是形状为 1×128000 的单通道张量；对于回归任务，每个样本由左右通道堆叠形成形状为 2×128000 的双通道张量。

考虑到不同实验样本的信号幅值范围可能存在差异，代码中对每个样本执行逐段标准化处理。设原始信号为 x ，均值为 μ ，标准差为 σ ，则归一化后的信号为：

$$\hat{x} = \frac{x - \mu}{\sigma + 10^{-6}} \quad (3-1)$$

当标准差接近零时，仅进行去均值操作，以避免除零问题。该策略有助于降低量纲差异对训练过程的影响，使网络更关注波形形态与通道间相对变化。

3.3 一维卷积特征提取网络

本文采用的一维卷积主干网络定义于 `src/leak_detection/models/signal_models.py`。网络由若干级卷积模块堆叠而成，每一级模块均包含以下操作：

1. 一层带步长的一维卷积，用于完成特征提取与时域降采样；
2. 批归一化层，用于稳定训练过程；
3. GELU 激活函数，用于增强非线性表达能力；

4. 第二层一维卷积与批归一化、GELU 组合，用于进一步提取局部模式。

模型配置中卷积通道数依次设置为 32、64、128 和 256，对应卷积核大小分别为 15、9、7 和 5，步长均为 4。通过多层降采样，长达 128000 点的原始时序被逐步压缩到较短的特征表示，再经过自适应平均池化聚合为全局特征向量。最后，采用全连接层构建任务头。

这一结构的优点在于实现简单、参数量可控，并且适合处理长度较长的一维信号。相比需要更大算力与更复杂位置编码机制的序列模型，一维卷积网络在当前数据规模和实验条件下更易训练，也更适合本科毕业设计阶段的工程实现。

3.4 分类头与回归头设计

3.4.1 Stage2 分类模型

Stage2 任务使用单通道输入，模型主干输出全局特征后，经由两层全连接网络映射到三维类别空间，最终输出对应三类标签的预测结果。分类任务损失函数采用交叉熵损失，其表达式为：

$$\mathcal{L}_{cls} = - \sum_{c=1}^C y_c \log \hat{y}_c \quad (3-2)$$

其中， C 表示类别数量， y_c 为真实标签的 one-hot 编码， $\hat{y}_c$ 为模型输出的类别概率。

3.4.2 Stage1 回归模型

Stage1 任务使用双通道输入，模型输出单一实数作为泄漏距离预测值。为增强对异常误差的鲁棒性，当前实现中优先采用 Smooth L1 损失：

$$\mathcal{L}_{reg}(d, \hat{d}) = \begin{cases} \frac{1}{2}(d - \hat{d})^2, & |d - \hat{d}| < 1 \\ |d - \hat{d}| - \frac{1}{2}, & |d - \hat{d}| \geq 1 \end{cases} \quad (3-3)$$

其中， d 为真实距离， $\hat{d}$ 为预测距离。相较于均方误差，Smooth L1 在误差较大时对离群点的敏感性更低，有利于提升回归训练的稳定性。

3.5 训练策略

统一训练流程定义于 `src/leak_detection/training/trainer.py`。当前实验采用 AdamW 优化器，初始学习率为 0.001，权重衰减为 0.0001，并使用余弦

退火学习率调度器。训练最大轮数设置为 40，早停轮数设置为 8，当验证集指标长期未提升时提前终止训练。

此外，为避免梯度爆炸对长时序训练造成不稳定影响，训练过程中对梯度范数进行裁剪，阈值为 1.0。对分类任务，验证指标选择准确率；对回归任务，重点关注平均绝对误差与均方根误差。训练完成后，程序自动加载最佳验证模型，并在测试集上输出最终指标。

第四章 实验设计与结果分析

4.1 实验环境与配置

本文实验基于 Python 与 PyTorch 框架完成，数据集构建与训练流程均通过命令行工具调用。当前项目提供了两个主要配置文件：`configs/stage2.yaml` 用于分类实验，`configs/stage1.yaml` 用于回归实验。两者在主干网络结构上保持一致，仅在输入形式、任务头与评价指标上有所区别。

从实验复现角度出发，本文建议固定随机种子为 42，保持训练集、验证集和测试集划分一致，以保证不同实验之间具有可比性。若后续进行超参数对比实验，可分别围绕卷积通道数、卷积核大小、损失函数和窗口长度展开。

4.2 评价指标

4.2.1 分类任务指标

对于 Stage2 分类任务，本文采用准确率、macro-F1 和混淆矩阵作为主要评价方式。准确率定义为：

$$Accuracy = \frac{N_{correct}}{N_{total}} \quad (4-1)$$

其中， $N_{correct}$ 表示预测正确的样本数量， N_{total} 表示测试样本总量。考虑到分类任务存在一定类别不均衡，本文进一步引入 macro-F1 指标。该指标先分别计算每个类别的 F1 值，再对各类别结果进行等权平均，因此能够更好地反映少数类识别效果。此外，本文同时统计片段级混淆矩阵与原始文件级混淆矩阵，用于分析不同类别之间的混淆关系。

4.2.2 回归任务指标

对于 Stage1 回归任务，本文采用平均绝对误差与均方根误差作为主要指标，分别表示为：

$$MAE = \frac{1}{N} \sum_{i=1}^N |d_i - \hat{d}_i| \quad (4-2)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (d_i - \hat{d}_i)^2} \quad (4-3)$$

其中， d_i 为真实距离， $\hat{d}_i$ 为预测距离。MAE 反映平均偏差水平，RMSE 对较大误差更加敏感，二者结合能够较全面地反映定位性能。

4.3 实验结果

基于当前仓库中的正式训练结果，本文分别对 **Stage2** 分类任务与 **Stage1** 回归任务进行分析。所有实验均采用相同的随机种子与文件级划分方式，以保证训练集、验证集与测试集之间具有可比性。

4.3.1 Stage2 分类结果

Stage2 任务以单通道分段信号为输入，输出正常状态与两类泄漏形态的三分类结果。实验结果如表4-1 所示。可以看出，模型在测试集上取得了极高的片段级分类性能，测试集片段级准确率达到 0.9968，片段级 macro-F1 达到 0.9972。进一步将同一原始文件下的所有片段预测进行聚合后，文件级准确率与文件级 macro-F1 均达到 1.0000，说明模型在当前随机文件级划分下，对未见测试文件具备很强的识别能力。

表 4-1 Stage2 分类任务测试结果

评测层级	指标	数值
片段级	Accuracy	0.9968
片段级	Macro-F1	0.9972
文件级	Accuracy	1.0000
文件级	Macro-F1	1.0000

从混淆矩阵看，片段级测试样本中仅存在一次误分类，即真实类别 1 的一个片段被误判为类别 2，其余样本均被正确识别。文件级混淆矩阵则全部位于主对角线上，表明测试集中 26 个原始文件均被正确分类。上述结果不仅说明总体准确率较高，也说明该结果并非仅由多数类样本支撑，而是在各类别上都表现稳定。

4.3.2 Stage1 距离回归结果

Stage1 任务以同一时间窗口下的左右双通道信号对为输入，输出泄漏距离预测值。实验结果如表4-2 所示。模型在验证集上的最佳平均绝对误差为 0.3148；在测试集上，平均绝对误差为 0.3703，均方根误差为 0.5934。测试误差相较验证集略有上升，但整体差距较小，表明模型在距离估计任务上具有较好的稳定性。

表 4-2 Stage1 回归任务结果

数据划分	指标	数值
验证集最优模型	MAE	0.3148
测试集	MAE	0.3703
测试集	RMSE	0.5934

若与简单统计基线进行比较，本文模型表现出明显优势。例如，在测试集上始终预测训练集均值或中位数时，平均绝对误差通常处于 3 以上，而本文模型的测试集 MAE 仅为 0.3703。这说明模型并非仅仅学习到了距离标签的整体分布，而是有效捕获了双通道信号模式与泄漏距离之间的映射关系。

表 4-3 两阶段任务主要实验结果汇总

任务	测试指标 1	测试指标 2	备注
Stage2 分类	Accuracy = 0.9968	Macro-F1 = 0.9972	文件级 Accuracy = 1.0000
Stage1 回归	MAE = 0.3703	RMSE = 0.5934	双通道距离估计

4.4 结果分析

综合分类与回归实验结果可以看出，本文提出的两阶段框架在当前数据集与划分设置下取得了较好的性能。对于 Stage2 分类任务，模型几乎实现了完美识别，说明基于一维卷积的特征提取方式能够较好地捕获分段信号中的泄漏形态差异。特别是在引入原始文件级聚合评测后，模型依然获得 1.0000 的文件级准确率与文件级 macro-F1，这表明该结果并非单纯由同一文件下多个相似片段造成的片段级虚高。

对于 Stage1 回归任务，测试集 MAE 为 0.3703，RMSE 为 0.5934，明显优于简单均值预测或中位数预测等统计基线，表明双通道输入确实为泄漏距离估

计提供了有效信息。由于当前距离标签为多个离散取值，该误差水平说明模型通常能够将预测结果控制在相邻距离档位附近，具有较好的距离估计能力。

需要指出的是，本文结果建立在当前随机文件级划分的基础上。虽然训练集、验证集与测试集之间不存在原始文件重叠，但测试集规模仍然相对有限，且不同文件之间可能仍具有较强的工况相似性。因此，本文将当前结果视为现阶段实验条件下的有效结论。后续若需进一步增强说服力，可在保持现有评测指标的基础上，设计更加严格的数据切分策略，并补充跨工况或跨批次泛化实验。

总体而言，当前实验结果验证了两阶段方案的有效性：分类任务能够可靠地区分正常状态与泄漏形态，回归任务能够在较小误差范围内估计泄漏距离。这为后续继续开展模型改进、切分优化和部署适配奠定了较为扎实的实验基础。

第五章 结论与展望

5.1 全文总结

本文围绕双通道管道传感信号的泄漏检测问题，完成了数据构建、任务拆分、模型设计与训练流程搭建。针对原始 CSV 时序数据，本文采用固定窗口切分方式构建了分类任务与回归任务所需的数据集，并提出了一个两阶段泄漏检测框架。该框架使用一维卷积神经网络对长时序信号进行建模，其中分类任务用于识别正常状态与泄漏形态，回归任务用于估计泄漏距离。

从工程实现角度看，本文工作已形成较为完整的实验流水线，包括原始数据自动切分、数据加载、模型训练、验证集选择与测试集评估等模块。该流程结构清晰、复现方便，为后续进一步开展对比实验与性能优化提供了基础。

5.2 后续工作展望

尽管本文已经完成了两阶段泄漏检测方法的基本实现，但仍有若干方向值得进一步研究：

1. 在数据层面，可进一步扩充不同工况、不同噪声条件和更多距离位置的实验样本，以提升模型泛化能力。
2. 在模型层面，可尝试引入多尺度卷积、残差结构、注意力机制或时频联合建模方法，以增强对复杂泄漏模式的识别能力。
3. 在任务层面，可考虑将分类与定位设计为联合学习框架，探索共享特征表示是否能够进一步提升整体性能。
4. 在应用层面，可围绕实时推理、模型轻量化和部署适配展开研究，为后续实际工程部署提供支持。

总体而言，本文完成的工作验证了基于分段时序信号与深度学习方法开展管道泄漏检测与定位的可行性，为后续进一步研究打下了基础。

参考文献

- [1] 李晟洁, 李翔, 张越, 等. 基于 Wi-Fi 信道状态信息的行走识别与行走参数估计 [J]. 软件学报, 2021, 32 (10): 3122–3138.
- [2] Kıymık M K, Güler I, Dizibüyük A, et al. Comparison of STFT and wavelet transform methods in determining epileptic seizure activity in EEG signals for real-time application [J]. Computers in biology and medicine, 2005, 35 (7): 603–616.
- [3] 周志华. 机器学习 [M]. 北京: 清华大学出版社, 2016: 181–185.

致 谢

英文摘要。此部分皆为 Times New Roman 字体。“ABSTRACT”为二号字加粗，居中显示。英文摘要内容采用正文样式。英文关键词与英文摘要内容间隔一行，无缩进左对齐书写。“KEY WORDS:”为四号字加粗，英文关键词采用正文样式，且换行不缩进，关键词之间用逗号分隔，词义和中文关键词相同。“ABSTRACT”和“KEY WORDS”一律用大写字母，每个关键词的首字母要大写。